Pontificia Universidad Católica de Chile
Facultad de Matemáticas
EYP3407 – Tópicos Aplicados en Estadística
Profesor: Eloy Alvarado Narváez
Ayudante: Andrés Díaz

Informe final

12 de noviembre de 2026

Javier Encina – Camila Moreno – Romina Navarro – Javiera Sotolincoñir

¿Cuánto mejora un modelo estadístico la predicción del caudal del día siguiente frente a mantener el caudal observado hoy?

Resumen ejecutivo

Escribe aquí el resumen ejecutivo del informe (máximo 250 palabras).

Problema y datos

Contexto y problema

Una cuenca corresponde a una zona donde el agua proveniente de lluvias, deshielos o manantiales desemboca en un cuerpo de agua común como un río, lago u océano. Las cuencas desempeñan un papel crucial pues determinan tanto cantidad como disponibilidad del agua, además de ser fundamentales para la agricultura (Washington State Department of Ecology, s. f.).

En ese contexto, la predicción del caudal del día siguiente constituye una herramienta potencialmente útil para la gestión y planificación de los recursos hídricos. Sin embargo, esta tarea presenta dificultades debido a la variabilidad de las condiciones meteorológicas y a las diferencias físicas entre cuencas, que pueden provocar comportamientos hidrológicos distintos.

Para responder la pregunta de investigación se comparan distintos procedimientos estadísticos con base en registros históricos y características del caudal, además de antecedentes de precipitación y temperatura.

Origen de los datos

Los datos provienen de CAMELS-CL (Catchment Attributes and Meteorology for Large Sample Studies, Chile), la primera base de datos hidrometeorológica y de atributos a gran escala desarrollada para Chile. Esta reúne información de 516 cuencas chilenas y fue presentada por Alvarez-Garreton et al. (2018).

En particular, los datos del informe corresponden a un subconjunto de datos de CAMELS-CL proporcionado para el **Caso 01 del curso EYP3407**, cuya copia de datos fue preparada el 12 de octubre 2026. Dicho subconjunto comprende 30 cuencas ubicadas entre los 33° y 40° de latitud sur, seleccionadas según la mayor cantidad de días con caudal observado entre 2000 y 2012, utilizando el identificador de cuenca como criterio de desempate. Se dispone de cuatro archivos originales con la información de los caudales Q, la precipitación y temperatura registrada, además de un diccionario con atributos adicionales. Todos los datos registrados corresponden a la ventana de tiempo generada entre el 1 de enero de 2000 y el 31 de diciembre de 2016 (Tabla 1).

Archivo	Descripción	Observaciones
`caudal_m3s.csv`	Caudal diario de las 30 cuencas, expresado en m^3/s.	6.210
`precipitacion_mm.csv`	Precipitación diaria CR2MET, expresada en mm/día.	6.210
`temperatura_media_c.csv`	Temperatura media diaria CR2MET, expresada en °C.	6.210
`atributos.csv`	Atributos físicos, climáticos e hidrológicos de las cuencas.	30

Tabla 1: Archivos originales utilizados en el análisis

Población, unidad de observación y variable respuesta

La **población de estudio** corresponde a las observaciones diarias de las 30 cuencas chilenas incluidas en el subconjunto de datos entregado en la respectiva ventana de tiempo.

La **unidad de observación** se define como un par entre la cuenca y la fecha, de manera que ambas variables en conjunto identifican cada registro. Se define Q_t como el caudal observado en una cuenca durante el día de origen t, con $t \in \{1, 2, \cdots, 6.210\}$ correspondiente a las fechas disponibles.

La **variable respuesta** corresponde al caudal del día siguiente definido como Q_{t+1}.

Muestra analítica

Para construir la muestra analítica (Figura 1) se reestructuró inicialmente `caudal_m3s.csv` que contiene 6.210 filas y 30 columnas correspondientes a las fechas e identificadores de las cuencas (respectivamente), de tal manera que en el resultado, cada fila contenga el par (ID cuenca - fecha t), generando un total de 186.300 observaciones (Tabla 2).

Posteriormente, las tres series se integraron mediante el identificador de cuenca y la fecha, obteniendo una base con la información del caudal de la cuenca Q, la precipitación P y la temperatura media Temp , estableciendo relaciones uno a uno entre registros. Se verificó la unicidad de las claves y la conservación de las 186.300 observaciones después de cada unión, manteniendo las 30 cuencas originales, sin duplicados.

Se identifican 3.038 valores faltantes del caudal y una observación con valor cero correspondiente a la cuenca del río Toltén, en la Región de La Araucanía, el 1 de enero de 2003. La cuenca del río Toltén presenta un clima templado cálido lluvioso con influencia mediterránea en sus sectores medio y bajo, y un clima templado frío lluvioso con influencia mediterránea en su sector precordillerano (Dirección General de Aguas [DGA], 2004, p. 5). Considerando estas características, el registro de caudal cero fue identificado como anómalo. Dado que el análisis contempla transformaciones logarítmicas, se decidió tratar dicho registro como un valor faltante, sin confirmar un error de medición. Con ello, se obtuvo un total de 3.039 registros de caudal faltantes.

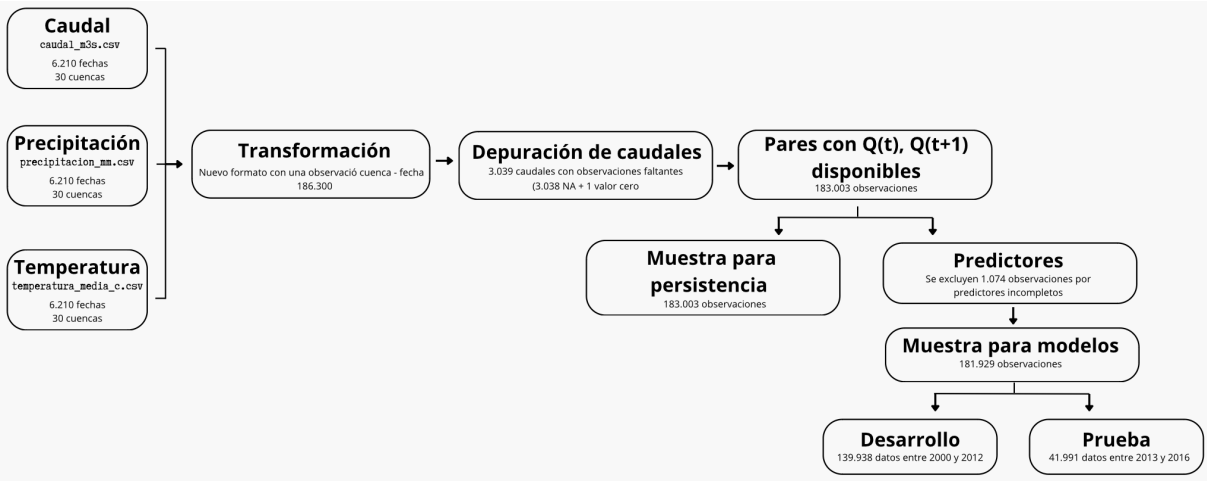


Figura 1: Esquema de construcción de la muestra

Etapa	**Observaciones**
Registros iniciales (30 cuencas × 6.210 días)	186.300
Cantidad de caudales NA	3.038
Cantidad de caudales con $Q_t = 0$	1
Total de caudales faltantes tras limpieza	3.039
Observaciones con Q_t y Q_{t+1} disponibles	183.003
Cantidad de obs. excluidas por predictores incompletos	1.104
Observaciones con respuesta y predictores completos	181.899
Observaciones entrenamiento	139.938
Observaciones prueba	41.961

Tabla 2: Construcción de la muestra

Disponibilidad de los predictores

A continuación se construyó la variable respuesta Q_{t+1} desplazando la serie para que cada fila Q_t tenga su respectivo Q_{t+1} verificando que no haya error en las asociaciones. Se conservaron únicamente los pares cuenca–fecha con valores observados tanto de Q_t como de Q_{t+1}, por lo que se dispone de 183.003 observaciones.

Adicionalmente, se construyeron variables predictoras a partir de la información disponible hasta el día de origen t: algunas asociadas al día anterior, como (Q_{t-1}, P_{t-1}), otras que dan cuenta de la precipitación acumulada en las últimas 3, 7 y 30 fechas y la temperatura media de las últimas 7 fechas.

La disponibilidad de estos predictores redujo la muestra a 181.899 registros completos. Finalmente, se estableció una separación temporal entre el período de desarrollo, correspondiente a 2000–2012, y el período reservado para prueba final, correspondiente a 2013–2016. Las observaciones se asignaron considerando la fecha de la respuesta, de modo que la información del período de prueba no se utilizara para el desarrollo de los modelos. La muestra quedó conformada por 139.938 registros de desarrollo y 41.961 de prueba.

A la hora de construir la base de datos para la elaboración de modelos, es importante considerar que las variables utilizadas como predictores deben estar disponibles en la fecha t para poder predecir $t+1$. En caso contrario, se incurre en fuga de información, pues el modelo se construye utilizando información futura. Por ello, es importante mencionar que las variables: Q_t, Q_{t-1}, P_t, P_{t-1}, la precipitación acumulada en las últimas 3, 7 y 30 fechas, además de la temperatura promedio de las últimas 7 fechas son conocidos en la fecha que se realiza la predicción t, por lo que su uso no implica fuga de información. Por su parte, el archivo `atributos.csv` contiene grupos de variables que, de ser usadas como predictoras, provocarían una fuga de información, como por ejemplo, medidas de resumen (promedios, medianas, etc) calculadas en base a la totalidad de los datos (Tabla 3).

Variable	Decisión	Motivo
Q_t	Incluir	Es caudal actual
Q_{t-1}	Incluir	Es caudal fecha anterior
$\log(Q_t)$	Incluir	Reduce asimetría
cambio_hoy	Incluir	$\log(Q_t)$ - $\log(Q_{t-1})$
P	Incluir	Precipitación actual
P_{t-1}	Incluir	Precipitación fecha anterior
lluvia_3d	Incluir	Precipit. acumulada últimas 3 fechas
lluvia_7d	Incluir	Precipit. acumulada últimas 7 fechas
lluvia_30d	Incluir	Precipit. acumulada últimas 30 fechas
Temp	Incluir	Temperatura promedio actual
temp_7d	Incluir	Temperatura promedio últimas 7 fechas
mes	Incluir	Estacionalidad
cuenca	Incluir	Id de cuenca.
Q_{t+1}	Excluir	Variable respuesta
cambio_manana	Excluir	$\log(Q_{t+1})$ - $\log(Q_t)$

Categoría	Decisión	Motivo
Topografía	Incluir	Características estables
Geología	Incluir	Cambio lento
Cobertura terrestre	Evaluar	Puede cambiar en el tiempo
Índices climáticos	Excluir	Fuga de información
Índices hidrológicos	Excluir	Fuga de información
Intervención humana	Evaluar	Puede variar temporalmente

Tabla 3: Auditoría de variables predictoras y atributos de las cuencas

Diseño de evaluación

Partición temporal

Dada la naturaleza temporal de los datos, se implementó un esquema de partición temporal que respeta el orden cronológico de las observaciones, separando las destinadas al desarrollo (2000 al 2012) de las destinadas para la etapa de prueba (2013 al 2016).

Dentro del período de desarrollo se realizaron siete validaciones anuales, correspondientes a los años 2006–2012. Para cada validación, el modelo se entrenó con los datos de los años anteriores y se evaluó en el año siguiente. Por ejemplo, **para validar en 2006 se utilizaron los datos desde el año 2000 al 2005 como entrenamiento**; para validar en 2007, se utilizaron los datos entre el 2000 y 2006, y así sucesivamente hasta 2012. Este procedimiento permitió evaluar los modelos en distintos años, aumentando progresivamente la información disponible para el entrenamiento y evitando fugas de información (Figura 2).

Se eligió comenzar la validación en 2006 para disponer de aproximadamente seis años de información histórica durante el primer entrenamiento. Asimismo, utilizar siete ventanas permitió considerar diferentes condiciones hidrometeorológicas, evitando que la elección del modelo dependiera exclusivamente del desempeño observado en un único año.

Los resultados de estas validaciones se utilizaron para seleccionar la configuración de cada modelo y determinar cuál presentaba el mejor desempeño. Una vez realizada esta selección, los modelos se ajustaron nuevamente utilizando todos los datos disponibles del período de desarrollo. Finalmente, se evaluaron en la prueba final de 2013–2016, sin utilizar los resultados de este período para modificar las decisiones tomadas anteriormente.

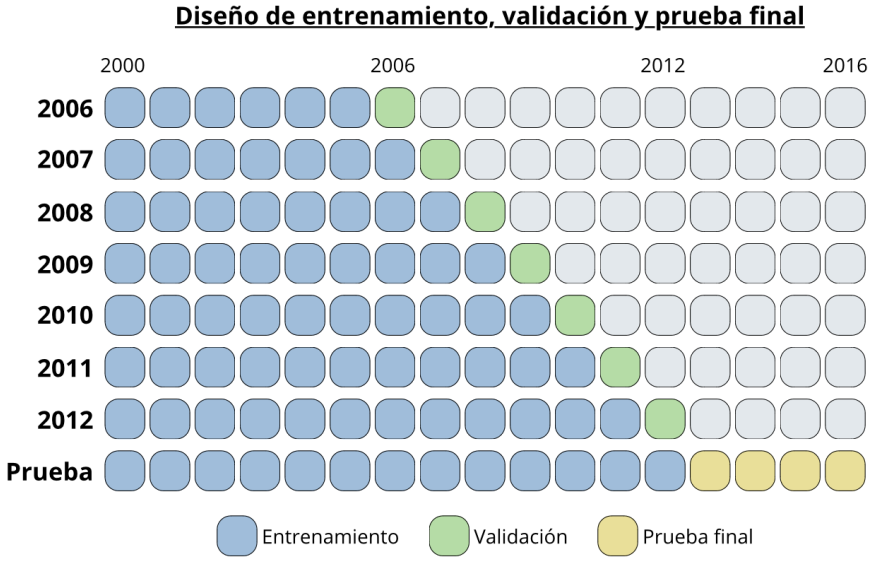


Figura 2: Esquema temporal de entrenamiento, validación y prueba final

Información disponible al momento de predecir

Para la i-ésima cuenca, la predicción $Q_{i,t+1}$ se realiza al cierre del día t. En consecuencia, los predictores deben ser conocidos al momento de realizar la predicción, tal como fue mencionado en el apartado anterior.

Las precipitaciones acumuladas de 3, 7 y 30 días y la temperatura promedio de 7 días se construyen utilizando exclusivamente observaciones hasta t, por lo que no se incurre en una fuga de información futura al usar dichas variables como predictores. El caudal del día siguiente Q_{t+1} se reserva para construir la respuesta y evaluar las predicciones, pues incorporarlo en los modelos implicaría predecir el futuro con información del futuro.

Se supone que la información meteorológica del día t se encuentra disponible al finalizar dicho día, de manera que puede ser utilizada para predecir el caudal del día siguiente.

Métricas y referencias de comparación

Como referencia principal para comparar modelos se utilizó el método de persistencia (1), que consiste en predecir que el caudal del día siguiente será igual al observado en el día actual.

$$\hat{Q}_{i,t+1}^{\text{persistencia}} = Q_{i,t} \tag{1}$$

Adicionalmente, se consideró una referencia estacional que predice el caudal del día siguiente utilizando la mediana histórica de los caudales observados en cada cuenca durante el mismo mes del año que se desea predecir. Esta mediana se calculó exclusivamente con los datos de entrenamiento de cada período, evitando incorporar información de las observaciones utilizadas para la evaluación. El uso de la mediana permite reducir la influencia de caudales extremos sobre esta referencia.

El desempeño de los modelos se comparó principalmente con la mejora relativa (2) del MAE (3) y RMSE (4) con respecto a la persistencia. Un resultado positivo indica que el modelo reduce el error respecto a la persistencia; un valor igual a cero representa un desempeño equivalente, mientras que uno negativo indica que el modelo presenta un error mayor.

$$\text{Mejora}_i = 1 - \frac{\text{Error}_{i,\text{modelo}}}{\text{Error}_{i,\text{persistencia}}} \tag{2}$$

$$\text{MAE}_i = \frac{1}{n_i} \sum_{t=1}^{n_i} \left| Q_{i,t+1} - \hat{Q}_{i,t+1} \right| \tag{3}$$

$$\text{RMSE}_i = \sqrt{\frac{1}{n_i} \sum_{t=1}^{n_i} (Q_{i,t+1} - \hat{Q}_{i,t+1})^2} \tag{4}$$

Nota: n_i corresponde al número de observaciones válidas evaluadas para la cuenca i.

Para comparar los modelos, primero se calcularon el MAE y el RMSE de cada procedimiento y de persistencia, utilizando los mismos días disponibles para cada cuenca y año de validación. A partir de estos valores se obtuvo la mejora relativa de cada modelo para cada cuenca.

Posteriormente, para cada año de validación se calculó la mediana de las mejoras de las 30 cuencas, con el objetivo de evitar que unos pocos resultados extremos influyeran excesivamente en la comparación. Finalmente, se promediaron las medianas obtenidas en las siete ventanas de validación (2006–2012), de manera que cada año tuviera la misma importancia en el resultado general.

Para seleccionar la mejor configuración de cada procedimiento y posteriormente el modelo recomendado, se utilizó como criterio principal la mayor mejora promedio del MAE frente a persistencia. Cuando las diferencias entre las alternativas eran de hasta 0,5 puntos porcentuales respecto de la mayor mejora en MAE, se utilizó la mejora del RMSE como criterio de desempate, seleccionando aquella configuración que presentara la mayor reducción de este error.

La selección se realizó utilizando exclusivamente los resultados del período de desarrollo. Posteriormente, los modelos se evaluaron en el período de prueba final (2013–2016), sin modificar las configuraciones seleccionadas.

Métodos

Modelos aplicados

Para predecir el caudal del día siguiente se utilizaron tres procedimientos estadísticos: regresión penalizada (M1), modelos aditivos generalizados (M2) y Random Forest (M3).

M1: Regresión penalizada (Ridge y Lasso)

Ridge reduce la magnitud de los coeficientes sin eliminarlos, mientras que Lasso puede llevar algunos de ellos a cero. Una de sus grandes ventajas es que permite controlar la complejidad del modelo mientras captura la relación lineal entre los predictores y la variable respuesta.

M2: Modelo aditivo generalizado (GAM)

A diferencia de la regresión penalizada, este modelo permite representar relaciones no lineales entre las variables explicativas y la respuesta mediante funciones suaves. Esto representa una fortaleza en el contexto hidrológico, pues el comportamiento del caudal frente a precipitaciones y temperatura no necesariamente debe ser lineal.

Se probaron distintas versiones del GAM para considerar que los ríos no necesariamente responden de la misma manera ante las mismas condiciones. Por ejemplo, una misma cantidad de precipitación puede producir un aumento importante del caudal en una cuenca y uno menor en otra. Por este motivo, se evaluaron modelos que permiten que la relación entre la precipitación y el cambio del caudal sea diferente para cada cuenca, así como la relación entre el caudal actual y su variación al día siguiente.

M3: Random Forest

Consiste en una combinación de múltiples árboles de decisión para generar las predicciones. Permite representar relaciones no lineales, pero tiene la ventaja de que además permite considerar interacciones a priori desconocidas entre las variables explicativas y la respuesta.

La comparación de M1, M2 y M3 permitió evaluar si una mayor flexibilidad del modelo se traducía en una mejora de la capacidad predictiva.

Preprocesamiento de los datos

Para el ajuste de los tres procedimientos se utilizó como variable respuesta el cambio logarítmico del caudal entre días consecutivos:

$$Y_{i,t} = \log(Q_{i,t+1}) - \log(Q_{i,t})$$

Se aplicó esta transformación por la asimetría de la distribución del caudal y por las diferencias de magnitud entre cuencas. Para las variables de precipitación utilizadas en M1 y M2 se aplicó la transformación $\log(1 + x)$ con el fin de reducir la asimetría y poder trabajar con observaciones cuya precipitación es igual a cero.

Una vez obtenidas las predicciones del cambio logarítmico, estas se transformaron nuevamente a la escala original de caudal, expresada en $\frac{m^3}{s}$.

Hiperparámetros y presupuesto de búsqueda

Para cada modelo se definió una grilla de valores para sus hiperparámetros, los cuales se compararon utilizando el diseño de validación cruzada previamente descrito (Tabla 4).

Para M1 se comparan 16 combinaciones de hiperparámetros, considerando coeficientes asociados a Ridge ($\alpha = 0$), Lasso ($\alpha = 1$), y ocho valores distintos de λ.

Procedimiento	Hiperparámetros evaluados	Configuraciones
M1: Ridge/Lasso	$\alpha \in \{0, 1\}$ $\lambda \in \{0; 0{,}0001; 0{,}0003; 0{,}001; 0{,}003; 0{,}01; 0{,}03; 0{,}1\}$	16
M2: GAM	Estructuras A, B y C con $k = 5, 10$; adicionalmente C con $k = 15$	7
M3: Random Forest	mtry $= 2, 3, 5$ con nodesize $= 5, 25$; adicionalmente mtry $= 8$ y nodesize $= 5$	7
Total		**30**

Tabla 4: Hiperparámetros y presupuesto de búsqueda por procedimiento

Para M2 se evalúan tres estructuras distintas: - A: incorpora un efecto propio para cada cuenca. - B: agrega una función suave de la precipitación actual específica por cuenca. - C: incorpora también una función suave específica por cuenca para el logaritmo del caudal actual.

Se evalúan $k = 5$ y $k = 10$ como valores que regulan la flexibilidad máxima de las funciones suaves, obteniendo seis configuraciones en total.

A partir de los diagnósticos realizados durante el desarrollo, se amplió la búsqueda incorporando una séptima configuración correspondiente a la estructura C con $k = 15$. Los parámetros de suavizado se estimaron dentro de cada ajuste mediante REML.

Para M3 se evalúan distintas combinaciones de dos hiperparámetros: - `mtry`: número de predictores considerados aleatoriamente en cada división de los árboles. - `nodesize`: establece el tamaño mínimo de los nodos terminales.

Inicialmente se evaluaron tres valores de `mtry` y dos de `nodesize`, obteniendo seis configuraciones.

Más tarde se amplió la búsqueda, incluyendo una séptima configuración.

En todos los ajustes se utilizaron 200 árboles y una submuestra de entrenamiento de 20.000 observaciones por árbol, manteniendo estos valores fijos durante la comparación de configuraciones.

En total, el presupuesto de búsqueda comprendió 16 configuraciones de M1, 7 de M2 y 7 de M3. Las configuraciones se compararon mediante su desempeño predictivo en las siete ventanas de validación, siguiendo los criterios de mejora relativa del MAE y RMSE definidos en el apartado de Diseño de evaluación.

Resultados

Presenta los resultados, tablas y gráficos.

Discusión

Interpreta los hallazgos y comenta sus limitaciones.

Reproducibilidad y contribuciones

Indica el código utilizado, los datos y las contribuciones del equipo.

Referencias

Washington State Department of Ecology. (s. f.). *What is a watershed and why does it matter?*, https://ecology.wa.gov/ecologys-work-near-you/river-basins-groundwater/what-is-a-watershed-and-why-does-it-matter

Alvarez-Garreton, C., Mendoza, P. A., Boisier, J. P., Addor, N., Galleguillos, M., Zambrano-Bigiarini, M., Lara, A., Puelma, C., Cortes, G., Garreaud, R., McPhee, J., & Ayala, A. (2018). The CAMELS-CL dataset: Catchment attributes and meteorology for large sample studies – Chile dataset. *Hydrology and Earth System Sciences, 22*(11), 5817–5846. https://doi.org/10.5194/hess-22-5817-2018

Dirección General de Aguas. (2004). *Diagnóstico y clasificación de los cursos y cuerpos de agua según objetivos de calidad: Cuenca del río Toltén.*

Anexo técnico

Agrega material complementario si corresponde.