Pontificia Universidad Católica de Chile
Facultad de Matemáticas
EYP3407 – Tópicos Aplicados en Estadística
Profesor: Eloy Alvarado Narváez
Ayudante: Andrés Díaz

Informe final

12 de noviembre de 2026

Javier Encina – Camila Moreno – Romina Navarro – Javiera Sotolincoñir

¿Cuánto mejora un modelo estadístico la predicción del caudal del día siguiente frente a mantener el caudal observado hoy?

Resumen ejecutivo

Escribe aquí el resumen ejecutivo del informe (máximo 250 palabras).

Problema y datos

¿Qué es una cuenca? - Listo

Una cuenca corresponde a una zona donde el agua proveniente de lluvias, deshielos o manantiales desemboca en un cuerpo de agua común como un río, lago u océano. Las cuencas desempeñan un papel crucial pues determinan tanto cantidad como disponibilidad del agua, además de ser fundamentales para la agricultura (Washington State Department of Ecology, s. f.).

Por qué es importante predecir cuencas y cual es la dificultad - Listo

En ese contexto, la predicción del caudal del día siguiente constituye una herramienta potencialmente útil para la gestión y planificación de los recursos hídricos. Sin embargo, esta tarea presenta dificultades debido a la variabilidad de las condiciones meteorológicas y a las diferencias físicas entre cuencas, que pueden provocar comportamientos hidrológicos distintos.

Cómo lo haremos - Listo

Para responder la pregunta de investigación se comparan distintos procedimientos estadísticos en base a registros históricos y características del caudal, además de antecenetes de precipitación y temperatura.

Origen de los datos - Listo

Los datos provienen de CAMELS-CL (Catchment Attributes and Meteorology for Large Sample Studies, Chile), la primera base de datos hidrometeorológica y de atributos a gran escala desarrollada para Chile. Esta reúne información de 516 cuencas chilenas y fue presentada por Alvarez-Garreton et al. (2018).

En particular, los datos del informe corresponden a un subconjunto de datos de CAMELS-CL proporcionado para el **Caso 01 del curso EYP3407**, cuya copia de datos fue preparada el 12 de octubre 2026. Dicho subconjunto comprende 30 cuencas ubicadas entre los 33° y 40° de latitud sur, seleccionadas según la mayor cantidad de días con caudal observado entre 2000 y 2012, utilizando el identificador de cuenca como criterio de desempate. Se dispone de cuatro archivos originales con la información de los caudales Q, la precipitación y temperatura registrada, además de un diccionario

con atributos adicionales. Todos los datos registrados corresponden a la ventana de tiempo generada entre 01/01/2000 y 31/12/2016 (Tabla 1).

Archivo	Descripcion	Observaciones
`caudal_m3s.csv`	Caudal diario de las 30 cuencas, expresado en m^3/s.	6.210
`precipitacion_mm.csv`	Precipitación diaria CR2MET, expresada en mm/día.	6.210
`temperatura_media_c.csv`	Temperatura media diaria CR2MET, expresada en °C.	6.210
`atributos.csv`	Atributos físicos, climáticos e hidrológicos de las cuencas.	30

Tabla 1: Archivos originales utilizados en el análisis

Definir población, unidad, respuesta - Listo

La **población de estudio** corresponde a las observaciones diarias de las 30 cuencas chilenas incluídas en el subconjunto de datos entregado en la respectiva ventana de tiempo.

La **unidad de observación** se define como un par entre la cuenca y la fecha, de manera que ambas variables en conjunto identifican cada registro. Se define Q_t como el caudal observado en una cuenca durante el día de origen t, con $t \in \{1, 2, \cdots, 6.210\}$ correspondiente a las fechas disponibles.

La **variable respuesta** corresponde al caudal del día siguiente definido como Q_{t+1}.

Construcción de la muestra estadística

Para construir la muestra analítica se re-estructuró inicialmente `caudal_m3s.csv` que contiene 6.210 filas y 30 columnas correspondientes a las fechas e identificadores de las cuencas (respectivamente), de tal manera que en el resultado, cada fila contenga el par (ID cuenca - fecha t), generando un total de 186.300 observaciones (Figura 1).

Posteriormente, las tres series se integraron mediante el identificador de cuenca y la fecha, estableciendo relaciones uno a uno entre registros. Se verificó la unicidad de las claves y la conservación de las 186.300 observaciones después de cada unión, manteniendo las 30 cuencas originales, sin duplicados.

De aquí para abajno no cuenta

Por su parte, el archivo `atributos.csv` contiene una fila por cuenca, por lo que su eventual integración a la base diaria correspondería a una relación muchos a uno. Las variables de caudal, precipitación y temperatura media se encuentran expresadas en m^3/s, mm/día y °C, respectivamente (Tabla 2).

Durante la revisión de los datos se identificaron 3.038 registros de caudal faltantes y una única observación con caudal igual a cero ($Q = 0$), correspondiente a la estación del río Toltén, en la Región de La Araucanía, el 1 de enero de 2003. La cuenca del río Toltén presenta un clima templado cálido lluvioso con influencia mediterránea en sus sectores medio y bajo, y un clima templado frío lluvioso con influencia mediterránea en su sector precordillerano (Dirección General de Aguas [DGA], 2004, p. 5). Considerando estas características, el registro de caudal cero fue identificado como potencialmente anómalo. Dado que el análisis contempla transformaciones logarítmicas, se decidió tratar dicho registro como un valor faltante, sin asumir que se haya confirmado un error de medición. Con ello, se obtuvo un total de 3.039 registros de caudal faltantes.

La variable respuesta se definió como el caudal observado al día siguiente, Q_{t+1}, expresado en m^3/s, estableciendo un horizonte de predicción de un día. Para construirla, los registros de caudal se desplazaron una fecha hacia adelante dentro de cada cuenca, evitando asociar observaciones pertenecientes a cuencas distintas. Posteriormente, se conservaron únicamente los pares cuenca–fecha con Q_t y Q_{t+1} disponibles, obteniendo una muestra de 183.003 observaciones. No se imputaron los caudales faltantes utilizados como respuestas, con el propósito de evaluar los modelos únicamente sobre valores efectivamente observados.

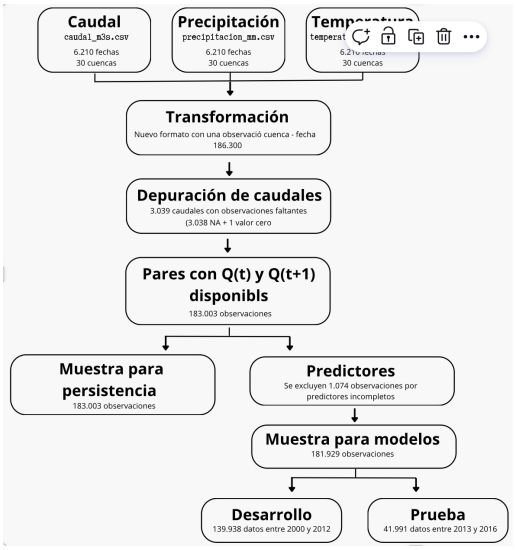


Figura 1: Construcción de la muestra analítica a partir de los datos CAMELS-CL.

Tabla 2: Construcción de la muestra

Etapa	Observaciones
Registros iniciales (30 cuencas x 6.210 días)	186.300
Cantidad de caudales NA	3.038
Cantidad de caudales con $Q_t = 0$	1
Total de caudales faltantes tras limpieza	3.039
Observaciones con Q_t y Q_{t+1} disponibles	183.003
Cantidad de obs. excluidas por predictores incompletos	1.074
Observaciones con respuesta y predictores completos	181.929
Observaciones entrenamiento	139.938
Observaciones prueba	41.991

Tabla 3: Inclusión y exclusión de variables predictoras por tipo

Tipo	Ejemplos	Decisión	Justificación
Caudal histórico	`Q`, `Q_ayer`, `log_Q`, `cambio_hoy`	Incluir	Información conocida hasta el día de origen.
Precipitación histórica	`P`, `P_ayer`, `lluvia_3d`, `lluvia_7d`, `lluvia_30d`	Incluir	Representa lluvias recientes y efectos retardados.
Temperatura histórica	`Temp`, `temp_7d`	Incluir	Aporta información térmica y sobre posibles deshielos.
Calendario	`mes`	Incluir	Permite representar patrones estacionales.
Topografía y localización	`area`, `elev_mean`, `slope_mean`, `gauge_lat`, `gauge_lon`	Incluir	Características físicas relativamente estables.
Geología y cobertura terrestre	`geol_class_1st`, `forest_frac`, `snow_frac`, `crop_frac`	Incluir	Requieren verificar estabilidad y disponibilidad histórica.
Índices climáticos	`p_mean_*`, `aridity_*`, `p_seasonality_*`, `pet_mean`	Excluir	Pueden incorporar información de períodos futuros.
Índices hidrológicos	`q_mean`, `Q5`, `Q95`, `baseflow_index`, `runoff_ratio_*`	Excluir	Pueden producir fuga de información.
Intervención humana	`big_dam`, `interv_degree`, `sur_rights_n`, `gw_rights_n`	Evaluar	Sus valores pueden cambiar durante el período estudiado.
Metadatos	`gauge_name`, `record_period_start`, `record_period_end`, `n_obs`	Excluir	Identifican estaciones o describen cobertura del registro.
Información futura	`Q_manana`, `cambio_manana`, `error_pers`	Excluir	Dependen del caudal futuro que se busca predecir.

Nota. La inclusión de variables meteorológicas supone su disponibilidad al cierre del día de origen. Los atributos físicos requieren revisar su disponibilidad histórica. Las variables excluidas no se utilizan como predictores. El asterisco en los nombres representa familias de variables.

Diseño de evaluación

Explica las particiones temporales, las métricas de evaluación y el modelo de referencia.

Métodos

Describe los modelos y el procedimiento de ajuste.

Resultados

Presenta los resultados, tablas y gráficos.

Discusión

Interpreta los hallazgos y comenta sus limitaciones.

Reproducibilidad y contribuciones

Indica el código utilizado, los datos y las contribuciones del equipo.

Referencias

Washington State Department of Ecology. (s. f.). *What is a watershed and why does it matter?*, https://ecology.wa.gov/ecologys-work-near-you/river-basins-groundwater/what-is-a-watershed-and-why-does-it-matter

Dirección General de Aguas. (2004). *Diagnóstico y clasificación de los cursos y cuerpos de agua según objetivos de calidad: Cuenca del río Toltén.*

Anexo técnico

Agrega material complementario si corresponde.