Pontificia Universidad Católica de Chile
Facultad de Matemáticas
EYP3407 – Tópicos Aplicados en Estadística
Profesor: Eloy Alvarado Narváez
Ayudante: Andrés Díaz

Informe final

12 de noviembre de 2026

Javier Encina – Camila Moreno – Romina Navarro – Javiera Sotolincoñir

¿Cuánto mejora un modelo estadístico la predicción del caudal del día siguiente frente a mantener el caudal observado hoy?

Resumen ejecutivo

Escribe aquí el resumen ejecutivo del informe (máximo 250 palabras).

Problema y datos

Contexto y problema

Una cuenca corresponde a una zona donde el agua proveniente de lluvias, deshielos o manantiales desemboca en un cuerpo de agua común como un río, lago u océano. Las cuencas desempeñan un papel crucial pues determinan tanto cantidad como disponibilidad del agua, además de ser fundamentales para la agricultura (Washington State Department of Ecology, s. f.).

En ese contexto, la predicción del caudal del día siguiente constituye una herramienta potencialmente útil para la gestión y planificación de los recursos hídricos. Sin embargo, esta tarea presenta dificultades debido a la variabilidad de las condiciones meteorológicas y a las diferencias físicas entre cuencas, que pueden provocar comportamientos hidrológicos distintos.

Para responder la pregunta de investigación se comparan distintos procedimientos estadísticos con base en registros históricos y características del caudal, además de antecedentes de precipitación y temperatura.

Origen de los datos

Los datos provienen de CAMELS-CL (Catchment Attributes and Meteorology for Large Sample Studies, Chile), la primera base de datos hidrometeorológica y de atributos a gran escala desarrollada para Chile. Esta reúne información de 516 cuencas chilenas y fue presentada por Alvarez-Garreton et al. (2018).

En particular, los datos del informe corresponden a un subconjunto de datos de CAMELS-CL proporcionado para el **Caso 01 del curso EYP3407**, cuya copia de datos fue preparada el 12 de octubre 2026. Dicho subconjunto comprende 30 cuencas ubicadas entre los 33° y 40° de latitud sur, seleccionadas según la mayor cantidad de días con caudal observado entre 2000 y 2012, utilizando el identificador de cuenca como criterio de desempate. Se dispone de cuatro archivos originales con la información de los caudales Q, la precipitación y temperatura registrada, además de un diccionario con atributos adicionales. Todos los datos registrados corresponden a la ventana de tiempo generada entre el 1 de enero de 2000 y el 31 de diciembre de 2016 (Tabla 1).

Archivo	Descripción	Observaciones
`caudal_m3s.csv`	Caudal diario de las 30 cuencas, expresado en m^3/s.	6.210
`precipitacion_mm.csv`	Precipitación diaria CR2MET, expresada en mm/día.	6.210
`temperatura_media_c.csv`	Temperatura media diaria CR2MET, expresada en °C.	6.210
`atributos.csv`	Atributos físicos, climáticos e hidrológicos de las cuencas.	30

Tabla 1: Archivos originales utilizados en el análisis

Población, unidad de observación y variable respuesta

La **población de estudio** corresponde a las observaciones diarias de las 30 cuencas chilenas incluidas en el subconjunto de datos entregado en la respectiva ventana de tiempo.

La **unidad de observación** se define como un par entre la cuenca y la fecha, de manera que ambas variables en conjunto identifican cada registro. Se define Q_t como el caudal observado en una cuenca durante el día de origen t, con $t \in \{1, 2, \cdots, 6.210\}$ correspondiente a las fechas disponibles.

La **variable respuesta** corresponde al caudal observado en la cuenca i el día siguiente al de origen, $Q_{i,t+1}$, medido en m^3/s.

Muestra analítica

Para construir la muestra analítica (Figura 1) se reestructuró inicialmente `caudal_m3s.csv` que contiene 6.210 filas y 31 columnas (una con la fecha y 30 con los identificadores de las cuencas), de tal manera que en el resultado, cada fila contenga el par (ID cuenca - fecha t), generando un total de 186.300 observaciones (Tabla 2).

Posteriormente, las tres series se integraron mediante el identificador de cuenca y la fecha, obteniendo una base con la información del caudal de la cuenca Q, la precipitación P y la temperatura media T, estableciendo relaciones uno a uno entre registros. Se verificó la unicidad de las claves y la conservación de las 186.300 observaciones después de cada unión, manteniendo las 30 cuencas originales, sin duplicados.

Se identifican 3.038 valores faltantes del caudal y una observación con valor cero correspondiente a la cuenca del río Toltén, en la Región de La Araucanía, el 1 de enero de 2003. La cuenca del río Toltén presenta un clima templado cálido lluvioso con influencia mediterránea en sus sectores medio y bajo, y un clima templado frío lluvioso con influencia mediterránea en su sector precordillerano (Dirección General de Aguas [DGA], 2004, p. 5). Considerando estas características, el registro de caudal cero fue identificado como anómalo. Dado que el análisis contempla transformaciones logarítmicas, se decidió tratar dicho registro como un valor faltante, sin confirmar un error de medición. Con ello, se obtuvo un total de 3.039 registros de caudal faltantes.

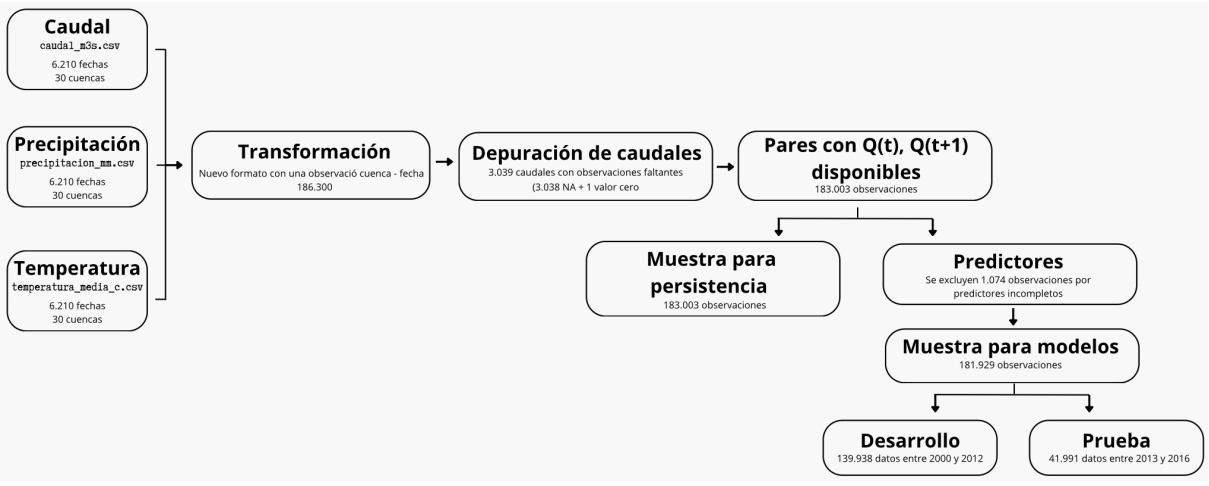


Figura 1: Esquema de construcción de la muestra

Etapa	**Observaciones**
Registros iniciales (30 cuencas × 6.210 días)	186.300
Cantidad de caudales NA	3.038
Cantidad de caudales con $Q_t = 0$	1
Total de caudales faltantes tras limpieza	3.039
Observaciones con Q_t y Q_{t+1} disponibles	183.003
Cantidad de obs. excluidas por predictores incompletos	1.104
Observaciones con respuesta y predictores completos	181.899
Observaciones entrenamiento	139.938
Observaciones prueba	41.961

Tabla 2: Construcción de la muestra

Disponibilidad de los predictores

A continuación se construyó la variable respuesta Q_{t+1} desplazando la serie para que cada fila Q_t tenga su respectivo Q_{t+1} verificando que no haya error en las asociaciones. Se conservaron únicamente los pares cuenca–fecha con valores observados tanto de Q_t como de Q_{t+1}, por lo que se dispone de 183.003 observaciones.

Adicionalmente, se construyeron variables predictoras a partir de la información disponible hasta el día de origen t: algunas asociadas al día anterior, como (Q_{t-1}, P_{t-1}), otras que dan cuenta de la precipitación acumulada en los últimos 3, 7 y 30 días y la temperatura media de los últimos 7 días.

La disponibilidad de estos predictores redujo la muestra a 181.899 registros completos. Finalmente, se estableció una separación temporal entre el período de desarrollo, correspondiente a 2000–2012, y el período reservado para prueba final, correspondiente a 2013–2016. Las observaciones se asignaron considerando la fecha de la respuesta, de modo que la información del período de prueba no se utilizara para el desarrollo de los modelos. La muestra quedó conformada por 139.938 registros de desarrollo y 41.961 de prueba.

A la hora de construir la base de datos para la elaboración de modelos, es importante considerar que las variables utilizadas como predictores deben estar disponibles en la fecha t para poder predecir $t+1$. En caso contrario, se incurre en fuga de información, pues el modelo se construye utilizando información futura. Por ello, es importante mencionar que las variables: Q_t, Q_{t-1}, P_t, P_{t-1}, la precipitación acumulada en los últimos 3, 7 y 30 días (incluido el día t), además de la temperatura promedio de los últimos 7 días, son conocidas en la fecha en que se realiza la predicción t, por lo que su uso no implica fuga de información. Por su parte, el archivo `atributos.csv` contiene grupos de variables que, de ser usadas como predictoras, provocarían una fuga de información, como por ejemplo, medidas de resumen (promedios, medianas, etc.) calculadas en base a la totalidad de los datos (Tabla 3).

Se distinguió además el identificador de cada cuenca de sus características físicas. En los modelos principales, cada cuenca se representa mediante su código, mientras que los atributos físicos estables se utilizaron solo para describir los resultados y en un análisis de sensibilidad.

Variable	Decisión	Motivo
Q_t	Incluir	Es caudal actual
Q_{t-1}	Incluir	Es caudal fecha anterior
$\log(Q_t)$	Incluir	Reduce asimetría
cambio_hoy	Incluir	$\log(Q_t)$ - $\log(Q_{t-1})$
P	Incluir	Precipitación actual
P_{t-1}	Incluir	Precipitación fecha anterior
lluvia_3d	Incluir	Precipit. acumulada últimas 3 fechas
lluvia_7d	Incluir	Precipit. acumulada últimas 7 fechas
lluvia_30d	Incluir	Precipit. acumulada últimas 30 fechas
Temp	Incluir	Temperatura promedio actual
temp_7d	Incluir	Temperatura promedio últimas 7 fechas
mes	Incluir	Estacionalidad
cuenca	Incluir	Id de cuenca.
Q_{t+1}	Excluir	Variable respuesta
cambio_manana	Excluir	Respuesta transformada; objetivo del ajuste

Categoría	Decisión	Motivo
Topografía	Admisible	Estable; solo en sensibilidad y diagnóstico
Geología	Admisible	Cambio lento; no utilizada
Cobertura terrestre	Admisible	Puede cambiar; solo en sensibilidad
Índices climáticos	Excluir	Fuga de información
Índices hidrológicos	Excluir	Fuga de información
Intervención humana	Admisible	Embalses; solo en sensibilidad y diagnóstico

Tabla 3: Auditoría de variables predictoras y atributos de las cuencas

Diseño de evaluación

Partición temporal

Dada la naturaleza temporal de los datos, se implementó un esquema de partición temporal que respeta el orden cronológico de las observaciones, separando las destinadas al desarrollo (2000 al 2012) de las destinadas para la etapa de prueba (2013 al 2016).

Dentro del período de desarrollo se realizaron siete validaciones anuales, correspondientes a los años 2006–2012. Para cada validación, el modelo se entrenó con los datos de los años anteriores y se evaluó en el año siguiente. Por ejemplo, **para validar en 2006 se utilizaron los datos desde el año 2000 al 2005 como entrenamiento**; para validar en 2007, se utilizaron los datos entre el 2000 y 2006, y así sucesivamente hasta 2012. Este procedimiento permitió evaluar los modelos en distintos años, aumentando progresivamente la información disponible para el entrenamiento y evitando fugas de información (Figura 2). Para que todas las respuestas del entrenamiento fueran conocidas antes del inicio de la validación, el entrenamiento incluyó días de origen solo hasta el 30 de diciembre del año previo; así, la última respuesta utilizada corresponde al 31 de diciembre y ninguna observación de entrenamiento utiliza el caudal de un día del año de validación. El mismo criterio se aplicó al separar el desarrollo de la prueba final.

Se eligió comenzar la validación en 2006 para disponer de aproximadamente seis años de información histórica durante el primer entrenamiento. Asimismo, utilizar siete ventanas permitió considerar diferentes condiciones hidrometeorológicas, evitando que la elección del modelo dependiera exclusivamente del desempeño observado en un único año.

Los resultados de estas validaciones se utilizaron para seleccionar la configuración de cada modelo y determinar cuál presentaba el mejor desempeño. Una vez realizada esta selección, los modelos se ajustaron nuevamente utilizando todos los datos disponibles del período de desarrollo. Finalmente, se evaluaron en la prueba final de 2013–2016, sin utilizar los resultados de este período para modificar las decisiones tomadas anteriormente.

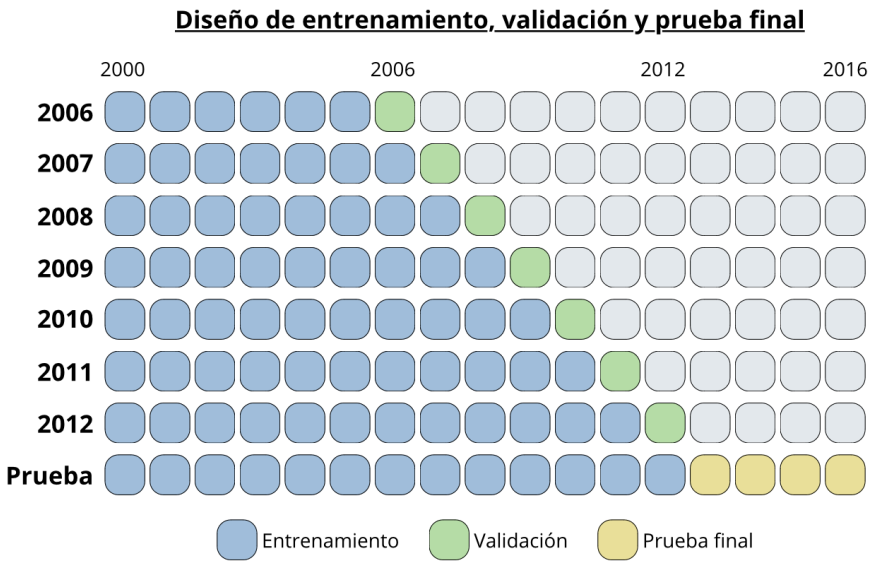


Figura 2: Esquema temporal de entrenamiento, validación y prueba final

Información disponible al momento de predecir

Para la i-ésima cuenca, la predicción $\hat{Q}_{i,t+1}$ se realiza al cierre del día t. En consecuencia, los predictores deben ser conocidos al momento de realizar la predicción, tal como fue mencionado en el apartado anterior.

Las precipitaciones acumuladas de 3, 7 y 30 días y la temperatura promedio de 7 días se construyen utilizando exclusivamente observaciones hasta t, por lo que no se incurre en una fuga de información futura al usar dichas variables como predictores. El caudal del día siguiente Q_{t+1} se reserva para construir la respuesta y evaluar las predicciones, pues incorporarlo en los modelos implicaría predecir el futuro con información del futuro.

Se supone que la información meteorológica del día t se encuentra disponible al finalizar dicho día, de manera que puede ser utilizada para predecir el caudal del día siguiente. Dado que los productos meteorológicos utilizados corresponden a reconstrucciones posteriores, el ejercicio constituye una evaluación retrospectiva bajo este supuesto de disponibilidad y no mide el desempeño operativo de un pronóstico en tiempo real.

Métricas y referencias de comparación

Como referencia principal para comparar modelos se utilizó el método de persistencia (1), que consiste en predecir que el caudal del día siguiente será igual al observado en el día actual.

$$\hat{Q}_{i,t+1}^{\text{persistencia}} = Q_{i,t} \tag{1}$$

Adicionalmente, se consideró una referencia estacional que predice el caudal del día siguiente mediante la mediana de los caudales diarios observados en la misma cuenca y en el mismo mes calendario del día a predecir, considerando todos los años del período de entrenamiento. De este modo, todos los días de un mismo mes reciben la misma predicción. En cada ventana de validación esta mediana se calculó exclusivamente con los años anteriores al año evaluado, y para la prueba final se utilizó el período completo de desarrollo (2000–2012), evitando incorporar información de las observaciones utilizadas para la evaluación. El uso de la mediana permite reducir la influencia de caudales extremos sobre esta referencia.

El desempeño de los modelos se comparó principalmente con la mejora relativa (2) del MAE (3) y RMSE (4) con respecto a la persistencia. Un resultado positivo indica que el modelo reduce el error

respecto a la persistencia; un valor igual a cero representa un desempeño equivalente, mientras que uno negativo indica que el modelo presenta un error mayor.

$$\text{Mejora}_i = 1 - \frac{\text{Error}_{i,\text{modelo}}}{\text{Error}_{i,\text{persistencia}}} \tag{2}$$

$$\text{MAE}_i = \frac{1}{n_i} \sum_{t=1}^{n_i} \left| Q_{i,t+1} - \hat{Q}_{i,t+1} \right| \tag{3}$$

$$\text{RMSE}_i = \sqrt{\frac{1}{n_i} \sum_{t=1}^{n_i} (Q_{i,t+1} - \hat{Q}_{i,t+1})^2} \tag{4}$$

Nota: n_i corresponde al número de observaciones válidas evaluadas para la cuenca i.

Para comparar los modelos, primero se calcularon el MAE y el RMSE de cada procedimiento y de persistencia, utilizando los mismos días disponibles para cada cuenca y año de validación. A partir de estos valores se obtuvo la mejora relativa de cada modelo para cada cuenca.

Posteriormente, para cada año de validación se calculó la mediana de las mejoras de las 30 cuencas. Como la mejora es relativa al error de persistencia de cada cuenca, esta agregación da el mismo peso a cada río y evita que el resultado quede dominado por las cuencas de mayor caudal o por unos pocos resultados extremos. Finalmente, se promediaron las medianas obtenidas en las siete ventanas de validación (2006–2012), de manera que cada año tuviera la misma importancia en el resultado general.

Para seleccionar la mejor configuración de cada procedimiento y posteriormente el modelo recomendado, se utilizó como criterio principal la mayor mejora promedio del MAE frente a persistencia, por ser la métrica principal del análisis. Cuando las diferencias entre las alternativas eran de hasta 0,5 puntos porcentuales respecto de la mayor mejora en MAE, se utilizó la mejora del RMSE como criterio de desempate, seleccionando aquella configuración que presentara la mayor reducción de este error. Por una omisión en el código, en M1 la configuración se seleccionó únicamente según la mayor mejora en MAE, sin aplicar el criterio de desempate (ver sección de Reproducibilidad).

La selección se realizó utilizando exclusivamente los resultados del período de desarrollo. Posteriormente, los modelos se evaluaron en el período de prueba final (2013–2016), sin modificar las configuraciones seleccionadas.

Métodos

Construcción de la especificación base

Antes de ajustar los tres procedimientos, se construyó una especificación base mediante una secuencia de regresiones lineales en la que la información se incorporó de manera progresiva, con el fin de identificar qué aportaba cada grupo de predictores. Se partió de un modelo que solo considera la tendencia reciente del río (cambio_hoy) y su nivel actual ($\log Q_t$), con un mismo efecto para todas las cuencas. Este modelo tuvo un desempeño prácticamente igual al de persistencia, lo que mostró que un comportamiento común para las 30 cuencas no era suficiente.

Al permitir que cada cuenca tuviera su propia velocidad de descenso del caudal, y luego su propia respuesta a la precipitación, el error bajó de forma consistente. En la validación de 2012 este modelo redujo el MAE en torno a un 11 % respecto de persistencia y superó a esta referencia en 26 de las 30 cuencas. Esto confirmó que la heterogeneidad entre cuencas es un componente central del problema. Finalmente, se incorporaron la temperatura del día, la temperatura promedio de los últimos 7 días y el mes, con el fin de representar la estacionalidad y el deshielo. Aunque en la regresión lineal estas variables no mejoraron de forma consistente el desempeño, se mantuvieron en la especificación común,

ya que los modelos más flexibles podrían aprovechar relaciones no lineales o interacciones con ellas. Toda esta construcción utilizó exclusivamente datos del período de desarrollo.

La especificación resultante se utilizó como punto de partida común. Los tres procedimientos utilizan los mismos once predictores, todos disponibles al cierre del día t; lo que difiere entre ellos es la forma en que se incorporan. M1 emplea exactamente esta especificación, mientras que M2 y M3 la representan con mayor flexibilidad, lo que les permite capturar relaciones no lineales e interacciones (Tabla 4). De este modo, las diferencias de desempeño entre procedimientos pueden atribuirse a su estructura y no a la información utilizada.

Predictores	**M1: Ridge**	**M2: GAM**	**M3: Random Forest**
`cambio_hoy`, $\log Q_t$	Lineal	Curva suave	Sin transformar
P_t, P_{t-1}, lluvia 3, 7 y 30 días	Lineal en $\log(1+x)$	Curva suave de $\log(1+x)$	Sin transformar
T_t, `temp_7d`	Lineal	Curva suave	Sin transformar
Mes	Categórica	Categórica	Categórica
Cuenca (código)	Intercepto propio	Intercepto propio	Categórica
Efectos propios por cuenca	Pendientes para $\log Q_t$, P_t, P_{t-1}, lluvia 3 días y `temp_7d`	Curvas para $\log Q_t$ y P_t ($k = 5$)	No se especifican; los árboles las aprenden
Configuración elegida	Ridge, $\lambda = 0{,}03$	Estructura C, $k = 10$	mtry = 8, nodesize = 5

Tabla 4: Predictores y su forma de inclusión en cada procedimiento

Modelos aplicados

Para predecir el caudal del día siguiente se utilizaron tres procedimientos estadísticos: regresión penalizada (M1), modelos aditivos generalizados (M2) y Random Forest (M3).

M1: Regresión penalizada (Ridge y Lasso)

Ridge reduce la magnitud de los coeficientes sin eliminarlos, mientras que Lasso puede llevar algunos de ellos a cero. Una de sus grandes ventajas es que permite controlar la complejidad del modelo mientras captura la relación lineal entre los predictores y la variable respuesta. En este caso, la penalización se aplica sobre la especificación base descrita anteriormente, que incluye efectos específicos por cuenca, por lo que el modelo es lineal en sus parámetros pero permite que cada río responda de forma distinta. Para que la penalización trate a todas las cuencas por igual, el identificador de cuenca se codificó sin una cuenca de referencia. Se espera que M1 capture el comportamiento promedio del caudal y las diferencias entre cuencas, gracias a sus efectos específicos por río. Sin embargo, al suponer relaciones lineales, podría fallar en crecidas, donde la respuesta del caudal a la precipitación no es proporcional, y en cuencas con deshielo, donde la temperatura y la estación interactúan de forma más compleja.

M2: Modelo aditivo generalizado (GAM)

A diferencia de la regresión penalizada, este modelo permite representar relaciones no lineales entre las variables explicativas y la respuesta mediante funciones suaves. Esto representa una fortaleza en el contexto hidrológico, pues el comportamiento del caudal frente a precipitaciones y temperatura no necesariamente debe ser lineal.

Se probaron distintas versiones del GAM para considerar que los ríos no necesariamente responden de la misma manera ante las mismas condiciones. Por ejemplo, una misma cantidad de precipitación puede producir un aumento importante del caudal en una cuenca y uno menor en otra. Por este motivo, se evaluaron modelos que permiten que la relación entre la precipitación y el cambio del caudal sea diferente para cada cuenca, así como la relación entre el caudal actual y su variación al día siguiente. Se espera que el GAM mejore a M1 en eventos de lluvia intensa y en la recesión posterior a una crecida, donde las relaciones son no lineales. Su principal limitación es que los efectos se suman entre sí, por lo que no captura interacciones que no se especifiquen explícitamente, como la

combinación de lluvia y temperatura en cuencas con nieve. Además, su costo computacional crece considerablemente al permitir curvas propias por cuenca.

M3: Random Forest

Consiste en una combinación de múltiples árboles de decisión para generar las predicciones. Permite representar relaciones no lineales, pero tiene la ventaja de que además permite considerar interacciones a priori desconocidas entre las variables explicativas. A diferencia de M1 y M2, utiliza las precipitaciones sin transformar, ya que los árboles no se ven afectados por la asimetría de los predictores.

Se espera que el Random Forest capture interacciones entre predictores sin necesidad de especificarlas, por ejemplo, que la misma lluvia tenga efectos distintos según la temperatura o la época del año. Sin embargo, sus predicciones se construyen promediando situaciones observadas en el entrenamiento, por lo que no puede extrapolar fuera de ese rango. Esto podría afectarlo ante caudales extremos nunca observados o ante condiciones persistentemente distintas, como una sequía prolongada. Además, es el modelo menos interpretable de los tres.

La comparación de M1, M2 y M3 permitió evaluar si una mayor flexibilidad del modelo se traducía en una mejora de la capacidad predictiva.

Preprocesamiento de los datos

Si bien la respuesta de interés es el caudal del día siguiente $Q_{i,t+1}$ en m^3/s, los tres procedimientos se ajustaron para predecir el cambio logarítmico del caudal entre días consecutivos:

$$Y_{i,t} = \log(Q_{i,t+1}) - \log(Q_{i,t}) \tag{5}$$

donde log corresponde al logaritmo natural. Un valor $Y_{i,t} = 0$ indica que el caudal se mantiene, lo que equivale a la predicción de persistencia, mientras que valores positivos o negativos representan, aproximadamente, el aumento o la disminución porcentual del caudal. Esta transformación requiere caudales estrictamente positivos, por lo que el registro con caudal cero se trató previamente como faltante.

Se aplicó esta transformación por la asimetría de la distribución del caudal y por las diferencias de magnitud entre cuencas. Para las variables de precipitación utilizadas en M1 y M2 se aplicó la transformación $\log(1 + x)$ con el fin de reducir la asimetría y poder trabajar con observaciones cuya precipitación es igual a cero.

Una vez obtenida la predicción del cambio logarítmico $\hat{Y}_{i,t}$, el caudal del día siguiente se recupera en la escala original como:

$$\hat{Q}_{i,t+1} = Q_{i,t}\, e^{\hat{Y}_{i,t}} \tag{6}$$

expresado en m^3/s. Dado que los modelos estiman el cambio esperado en escala logarítmica, esta retransformación no entrega la media del caudal del día siguiente, sino un valor que tiende a subestimarla. Si el cambio logarítmico se distribuye de forma aproximadamente simétrica, este valor corresponde a la mediana condicional del caudal, lo que resulta coherente con utilizar el MAE como métrica principal. No se aplicó una corrección de sesgo en la retransformación.

Hiperparámetros y presupuesto de búsqueda

Para cada modelo se definió una grilla de valores para sus hiperparámetros, los cuales se compararon utilizando el diseño de validación temporal con origen creciente previamente descrito (Tabla 5).

Para M1 se comparan 16 combinaciones de hiperparámetros, considerando coeficientes asociados a Ridge ($\alpha = 0$), Lasso ($\alpha = 1$), y ocho valores distintos de λ. Con $\lambda = 0$ ambas alternativas coinciden con la regresión lineal sin penalización, por lo que en la práctica se evaluaron 15 modelos distintos.

Una grilla inicial con valores de λ entre 1 y 10 se descartó porque en todos los casos producía un modelo equivalente a persistencia, con todos los coeficientes anulados.

Procedimiento	**Hiperparámetros evaluados**	**Configuraciones**
M1: Ridge/Lasso	$\alpha \in \{0, 1\}$ $\lambda \in \{0;\ 0{,}0001;\ 0{,}0003;\ 0{,}001;\ 0{,}003;\ 0{,}01;\ 0{,}03;\ 0{,}1\}$	16
M2: GAM	Estructuras A, B y C con $k = 5, 10$; adicionalmente C con $k = 15$	7
M3: Random Forest	mtry $= 2, 3, 5$ con nodesize $= 5, 25$; como el mejor modelo fue con nodesize $= 5$ adicionalmente se probó mtry $= 8$ y nodesize $= 5$	7
Total		**30**

Tabla 5: Hiperparámetros y presupuesto de búsqueda por procedimiento

Para M2 se evalúan tres estructuras distintas: - A: incorpora un efecto propio para cada cuenca. - B: agrega una función suave de la precipitación actual específica por cuenca. - C: incorpora también una función suave específica por cuenca para el logaritmo del caudal actual.

Se evalúan $k = 5$ y $k = 10$ como valores que regulan la flexibilidad máxima de las curvas comunes a todas las cuencas, obteniendo seis configuraciones; las curvas específicas por cuenca se mantuvieron con $k = 5$ en todos los casos. El mes y el identificador de cuenca se incorporaron como términos categóricos. Los parámetros de suavizado se estimaron dentro de cada ajuste mediante REML.

Con $k = 10$, varias de las curvas comunes utilizaban prácticamente toda la flexibilidad permitida, lo que indicaba que el límite fijado podía estar restringiendo la forma de esas relaciones. Por ello, se amplió la búsqueda con una séptima configuración, correspondiente a la estructura C con $k = 15$. Esta no mejoró el desempeño en desarrollo, por lo que se mantuvo $k = 10$.

Para M3 se evalúan distintas combinaciones de dos hiperparámetros: - `mtry`: número de predictores considerados aleatoriamente en cada división de los árboles. - `nodesize`: establece el tamaño mínimo de los nodos terminales.

Inicialmente se evaluaron tres valores de `mtry` (2, 3 y 5) y dos de `nodesize` (5 y 25), obteniendo seis configuraciones. Como la mejor configuración inicial correspondía al mayor valor de `mtry` de la grilla, se amplió la búsqueda con una séptima configuración (`mtry` $= 8$, `nodesize` $= 5$), que mejoró levemente el desempeño en desarrollo (36,6 % frente a 36,0 % de mejora en MAE) y fue la configuración seleccionada.

En todos los ajustes se utilizaron 200 árboles y una submuestra de entrenamiento de 20.000 observaciones por árbol, manteniendo estos valores fijos durante la comparación de configuraciones.

En total, el presupuesto de búsqueda comprendió 16 configuraciones de M1, 7 de M2 y 7 de M3. Las configuraciones se compararon mediante su desempeño predictivo en las siete ventanas de validación, siguiendo los criterios de mejora relativa del MAE y RMSE definidos en el apartado de Diseño de evaluación.

Resultados

Para comparar los modelos, lo primero que se hizo fue analizar cada desempeño en el conjunto de desarrollo. Cuyas particiones ya fueron establecidas y detalladas en la sección de diseño de evaluación. La tabla 1 va a resumir cada rendimiento de los 3 modelos que se realizaron y las dos referencias, o sea persistencia y estacional, todos ordenados por su mejora mediana en el MAE. Dentro de esta tabla la columna “Mejora MAE” indica el porcentaje en que el modelo reduce su error absoluto respecto a la persistencia, mientras que la columna “Peor año (MAE)” mostrará el desempeño del modelo

en el año donde logró la menor mejora y "Ríos donde gana" va a indicar en cuántas de nuestras combinaciones de río y año el modelo superó la persistencia. Y como se puede observar, Random Forest fue el que mejor desempeño obtuvo, reduciendo el error en un 36.6 % en comparación con la persistencia. El modelo GAM logró una mejora del 27 %, mientras que la regresión penalizada solo tuvo una mejora del 14.1 %. La referencia estacional nos indicó un error negativo, reafirmando que teniendo conocimiento sobre cuánta agua trae el río hoy es la información más importante para predecir el de mañana. Ya habiendo seleccionado el modelo de Random Forest, se evaluó en el conjunto de testeo final que contiene desde el año 2013 hasta el 2016, periodo el cual nuestro modelo nunca vio y que además coincidió con una megasequía en la zona central de nuestro país. La tabla 2 muestra que Random Forest se mantiene como el mejor alcanzando una mejora del 35.1 % en MAE y un 26.5 % en RMSE frente a la persistencia. En esta misma tabla también se puede observar la columna "Ríos gana" que va a contar en cuántas de las 30 cuencas el modelo superó la persistencia y los "Días evaluados" que sería la cantidad de días con datos válidos que se utilizaron en la comparación. GAM por su parte, obtuvo una mejora del 25.6 %, mientras que la regresión penalizada se quedó con un 14.1 % de mejora. Estos resultados son muy relevantes para demostrar que nuestro modelo tiene una capacidad predictiva que se mantiene en el tiempo, incluso cuando las condiciones climáticas cambian drásticamente hacia un clima más seco.

Desarrollo (2006–2012)

Modelo	Mejora MAE	Mejora RMSE	Peor año (MAE)	Pares río–año (de 210)
M3 Random Forest	**36.6 %**	**31.0 %**	29.7 %	199
M2 GAM	27.0 %	26.1 %	19.9 %	180
M1 Ridge/Lasso	14.1 %	12.4 %	8.4 %	177
Persistencia	0.0 %	0.0 %	0.0 %	0
Estacional	-276.3 %	-123.6 %	-439.6 %	0

Tabla 2. Prueba final (2013-2016)

Modelo	Mejora MAE	Mejora RMSE	Ríos gana	Días evaluados
M3 Random Forest	**35.1 %**	**26.5 %**	29	41.961
M2 GAM	25.6 %	21.3 %	27	41.961
M1 Ridge/Lasso	14.1 %	11.1 %	26	41.961
Persistencia	0.0 %	0.0 %	0	41.961
Estacional	-265.9 %	-107.7 %	0	41.961

Tabla 6: Mejora mediana frente a persistencia en desarrollo (promedio de 7 ventanas) y en la prueba final. La columna de la derecha de cada tabla indica en cuántos pares río–año o cuencas el modelo superó a la persistencia.

Con la finalidad de comprender en que se basa Random Forest para realizar sus predicciones, la tabla 3 nos indica la importancia de variables. Para calcular esta relevancia, el modelo usa una técnica de permutación en la cual se desordenan aleatoriamente los valores de una variable, para así eliminar su relación con el caudal y medir cuánto aumenta el error. La columna %IncMSE mide que tanto aumenta el error al eliminar esa variable. Y como se puede observar, el modelo se apoya mucho en la cuenca, seguida de por el nivel del río y la memoria a corto plazo. Esto nos demuestra que el modelo captura la heterogeneidad de los atributos físicos de cada río.

Variable	%IncMSE (Aumento del error al permutar)
cuenca	**47.80**
log_Q	40.42
P	32.00
cambio_hoy	31.18
mes	22.71
Temp	15.04
lluvia_3d	14.18
P_ayer	9.68
lluvia_30d	9.20
lluvia_7d	8.85
temp_7d	8.29

Tabla 7: Importancia de las variables en el modelo Random Forest.

Para ver cómo cambia el rendimiento del modelo entre cuencas, la Figura 3 muestra la mejora en

MAE de cada cuenca en la prueba final según su altura media. Los puntos azules son cuencas sin embalses grandes los naranjos, con embalse. Se observa que el modelo funciona mejor en las cuencas bajas (bajo 1.000 m), donde varias superan el 40 % de mejora, y que a medida que aumenta la altura la mejora va disminuyendo, llegando a valores cercanos a cero en las cuencas más altas. Algo parecido pasa con las cuencas con embalse, donde la mejora también es menor. Esto tiene sentido, ya que en esas cuencas el caudal depende del deshielo o de la regulación, cosas que el modelo no alcanza a captar con las variables que usamos.

Para medir la incertidumbre del 35,1 % de mejora en la prueba, usamos un bootstrap por bloques de 30 días con 1000 réplicas. Remuestreamos bloques de días consecutivos manteniendo juntas las 30 cuencas de cada fecha, porque un día se parece al siguiente y una misma lluvia afecta a varios ríos a la vez. La Figura **??** muestra el resultado: el intervalo al 95 % para la mejora en MAE va de 30,3 % a 38,5 % (y de 22,4 % a 32,3 % para el RMSE), y ninguna réplica quedó en cero o por debajo. Hay que tener en cuenta que el modelo no se volvió a ajustar en cada réplica, así que el intervalo solo refleja la variación por los días de prueba y no la incertidumbre de haber elegido y entrenado el modelo.

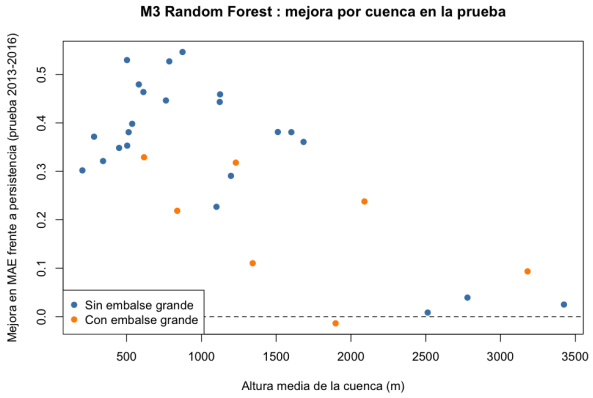


Figura 3: Mejora por cuenca según altura y embalses.

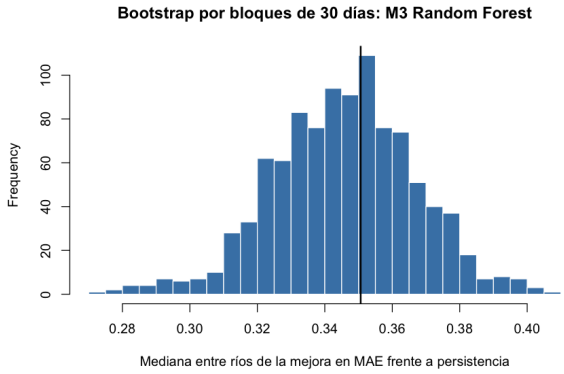


Figura 4: Distribución Bootstrap de la mejora en MAE.

Análisis de sensibilidad

A través de análisis de sensibilidad se evaluaron dos decisiones de representación de los datos y una de validación, en todas ellas con los datos de desarrollo (Tablas~8 y~9).

Tabla 8: Sensibilidades de representación de los datos para M3 (desarrollo, promedio de las 7 ventanas 2006–2012). Mejora relativa frente a persistencia.

Variante	Mejora MAE	Mejora RMSE	Peor año (MAE)	Dif. MAE
M3 ganador (cambio log, código de cuenca)	0,366	0,310	0,297	—
S1: respuesta en m^3/s	0,243	0,225	0,144	−0,123
S3: atributos físicos en vez de cuenca	0,354	0,295	0,300	−0,012

S1: escala de la respuesta. Cuando no realizamos un cambio logarítmico respecto al caudal de hoy, sino que modelamos el caudal de mañana directamente en m^3/s, la mejora de M3 en comparación con persistencia baja en MAE de 0,366 a 0,243, y la del peor año, de 0,297 a 0,144. Cuando se aplica la escala logarítmica, se ponen a un mismo nivel cuencas con caudales muy distintos y se fija la persistencia como cambio cero (punto de partida natural). Esta transformación es necesaria, pues de lo contrario el ajuste queda dominado por los ríos más grandes y el desempeño es peor y más inestable entre años.

S3: identificación de la cuenca. Cuando reemplazamos el código de cuenca por atributos físicos estables (área, elevación media, pendiente, fracción de bosque y de nieve, presencia de embalse y latitud), la mejora en MAE baja levemente, de 0,366 a 0,354. Esto indica que el modelo no depende de memorizar cada cuenca, pues gran parte de lo que aprende está explicado por sus características físicas.

Tabla 9: Sensibilidad de validación: configuración elegida en cada familia al validar con 7 ventanas (2006–2012) o con 3 ventanas (2010–2012). Mejora en MAE frente a persistencia.

	7 ventanas		3 ventanas	
Familia	Configuración	Mejora MAE	Configuración	Mejora MAE
M1 ridge/lasso	ridge, $\lambda = 0{,}001$	0,136	ridge, $\lambda = 0{,}03$	0,133
M2 GAM	C_k10	0,270	C_k10	0,226
M3 random forest	mtry 8, nodo 5	**0,366**	mtry 8, nodo 5	**0,340**

En negrita, la familia elegida con cada esquema: M3 en ambos casos.

{En negrita, la familia elegida con cada esquema: M3 en ambos casos.} \end{table}

S2: período de validación. Al elegir los modelos con 3 ventanas (2010–2012) en lugar de 7 (2006–2012), la elección es estable: M3 sigue siendo la familia elegida, con la misma configuración, y M2 también mantiene la suya. Por lo tanto, la recomendación no depende de los años usados para validar.

Discusión

Para responder a nuestra pregunta de investigación, los resultados obtenidos demuestran que sí es posible mejorar la predicción del caudal del día siguiente contra la persistencia. Random Forest redujo el error en un 35.9 % en el período de prueba final, superando por bastante a M1 y M2. Esto se puede explicar debido a la relación entre las variables asociadas al clima y el caudal no es lineal, sino que está llena de umbrales e interacciones complejas. Mientras que la regresión penalizada asume relaciones lineales. Random Forest va a dividir los datos en múltiples árboles, capturando todas estas relaciones no lineles. Además al observar la importancia de las variables podemos ver que el modelo se va a apoyar mucho en la identidad de la cuenca y en el nivel actual del río, confirmando que el modelo aprendió que cada río tiene características únicas.

Pero, es importante informar sobre los límites del modelo para generalizar. Ya que el análisis geográfico evidenció que hay un caso en el que no es confiable: Las cuencas cordilleranas. Ya que el modelo sirve bastante en las cuencas con una altura menor a 1.000 metros, donde logra reducir el error hasta un 50 %. Pero en las cuencas sobre los 1.500 metros, la mejora cae bastante, llegando a casos negativos. Esto no es un fallo sino que es una falta de información, ya que en la cordillera, el agua de los ríos viene del derretimiento de de la nieve acumulada y nuestra base no presentaba variables que midieran esto.

Por otro lado la validación temporal en el conjunto de prueba final agregó una complicación ya que en este periodo coincidió con una megasequía en la zona central de Chile. Por loq ue tuvo que predecir en un rango de condiciones que el modelo no conocía, Incluso así el modelo pudo mantener una mejora relativa de un 35.9 % frente a la persistencia, pero sus errores absolutos aumentaron. Esto debido a que el modelo se quedó sin referencias temporales para hacer sus comparaciones. Esto nos muestra que ningún modelo entrenado con datos históricos puede predecir con seguridad un cambio climático extremo. Por lo que estos modelos deben ser actualizados y ser reentrenados constantemente.

Finalmente, para definir la utibilidad real y las condiciones del uso de este modelo. Las sensibilidades validaron nuestras decisiones metodológicas. Ya que el utilizar la escala logarítmica resultó ser muy relevante para evitar que los ríos con un gran caudal afectaran el aprendizaje del algoritmo, asegurando un equilibrio para todas las cuencas. Además, cuando se comprobó que el modelo mantiene su alta capacidad para predecir usando solamente los atributos físicos como el área y la altura en vez de usar el nombre del río, confirmamos que el modelo captura patrones en las características de los ríos. Esto ayuda a que podamos usarlo en cuencas nuevas, siempre que tengan características similares. Con esto podemos confirmar que Random Forest es un modelo muy recomendable para predecir crecidas en ríos de valles y zonas lluviosas. Pero, no debe usarse para los ríos de zonas cordilleranas, ya que en estas zonas el flujo del agua depende del derretimiento de la nieve. Finalmente, como se mencionó. Al estar constantemente cambiando el clima, este modelo debe ser actualizado frecuentemente para mantener su uso en el futuro.

Reproducibilidad y contribuciones

Código y ejecución

Todo el análisis se encuentra en el repositorio público https://github.com/romi2134/Topicos-Final (versión utilizada: commit [HASH FINAL]). Los datos de entrada corresponden a los archivos del paquete caso01_camels_cl.zip entregado por el curso , descomprimidos en la carpeta datos/ sin modificaciones.

El análisis se ejecuta desde la carpeta del repositorio con el comando Rscript –vanilla Codigo_principal.R, que realiza la preparación de los datos, las particiones, el ajuste de los modelos y, al final, ejecuta bloques_11_16.R, donde se hacen la prueba final, el bootstrap, el diagnóstico y las sensibilidades. Las tablas y figuras quedan guardadas en la carpeta resultados/. Luego, el informe se genera con quarto render Informe_UC.qmd. Se fijaron semillas en todos los pasos aleatorios (set.seed(3407) para los modelos y set.seed(2026) para el bootstrap).

El análisis se corrió en R 4.5.3 sobre macOS (procesador Apple, arquitectura arm64), usando los paquetes glmnet 4.1-10, Matrix 1.7-4, mgcv 1.9-4 y randomForest 4.7-1.2. El Random Forest se ajustó en paralelo con 2 núcleos. La ejecución completa tarda aproximadamente [90] minutos, de los cuales cerca de 40 corresponden a la búsqueda de configuraciones del Random Forest.

Contribuciones

Si bien cada integrante se enfocó en ciertas partes del trabajo, todos revisamos el código, los resultados y el informe completo.

- Javier Encina: implementación de M3 (Random Forest), análisis de resultados y discusión.
- Camila Moreno: limpieza de los datos, implementación de M1 (Ridge/Lasso) y M2 (GAM) y análisis de resultados.
- Romina Navarro: redacción del informe, presentación y organización del repositorio.
- Javiera Sotolincoñir: limpieza y construcción de la base de datos y análisis de resultados.

Declaración de uso de IA

Se utilizó ChatGPT entre el 4/11/2026 y el 11/11/2026 como apoyo para programación y depuración del código, revisión de redacción y tablas.
principalmente en limpieza de datos, implementación de métodos, resumen de resultados. Todo el código fue ejecutado y sus resultados verificados por el equipo, y las cifras del informe se contrastaron con las salidas generadas en resultados/.

Referencias

Washington State Department of Ecology. (s. f.). *What is a watershed and why does it matter?*, https://ecology.wa.gov/ecologys-work-near-you/river-basins-groundwater/what-is-a-watershed-and-why-does-it-matter

Alvarez-Garreton, C., Mendoza, P. A., Boisier, J. P., Addor, N., Galleguillos, M., Zambrano-Bigiarini, M., Lara, A., Puelma, C., Cortes, G., Garreaud, R., McPhee, J., & Ayala, A. (2018). The CAMELS-CL dataset: Catchment attributes and meteorology for large sample studies – Chile dataset. *Hydrology and Earth System Sciences, 22*(11), 5817–5846. https://doi.org/10.5194/hess-22-5817-2018

Garreaud, R. D., Boisier, J. P., Rondanelli, R., Montecinos, A., Sepúlveda, H. H., & Veloso-Aguila, D. (2020). The Central Chile Mega Drought (2010–2018): A climate dynamics perspective. *International Journal of Climatology, 40*(1), 421–439. https://doi.org/10.1002/joc.6219

Dirección General de Aguas. (2004). *Diagnóstico y clasificación de los cursos y cuerpos de agua según objetivos de calidad: Cuenca del río Toltén.*

Anexo técnico

Agrega material complementario si corresponde.