TÓPICOS APLICADOS EN ESTADÍSTICA - EYP3407
12/11/2026

¿Cuánto mejora un modelo la predicción del caudal de mañana?

COMPARACIÓN FRENTE A PERSISTENCIA EN 30 CUENCAS CHILENAS, CAMELS-CL 2000–2016

Romina Navarro Javier Encina Camila Moreno Javiera Sotolincoñir





Problema: predecir el caudal del día siguiente

Una cuenca corresponde a una **zona donde el agua proveniente de lluvias, deshielos o manantiales desemboca en un cuerpo de agua común** (Washington State Department of Ecology, s. f.).

Característica	**Descripción**
Fecha de preparación	12 de octubre de 2026
Cantidad de cuencas	30
Ubicación geográfica	Entre los 33° y 40° de latitud sur
Criterio de selección	Mayor cantidad de días con caudal observado entre 2000 y 2012
Criterio de desempate	Identificador de cuenca
Período de observación	1 de enero de 2000 al 31 de diciembre de 2016

Cuadro 1: Características del subconjunto de datos

CAMELS-CL explorer

CAMELS-CL

(CR)²

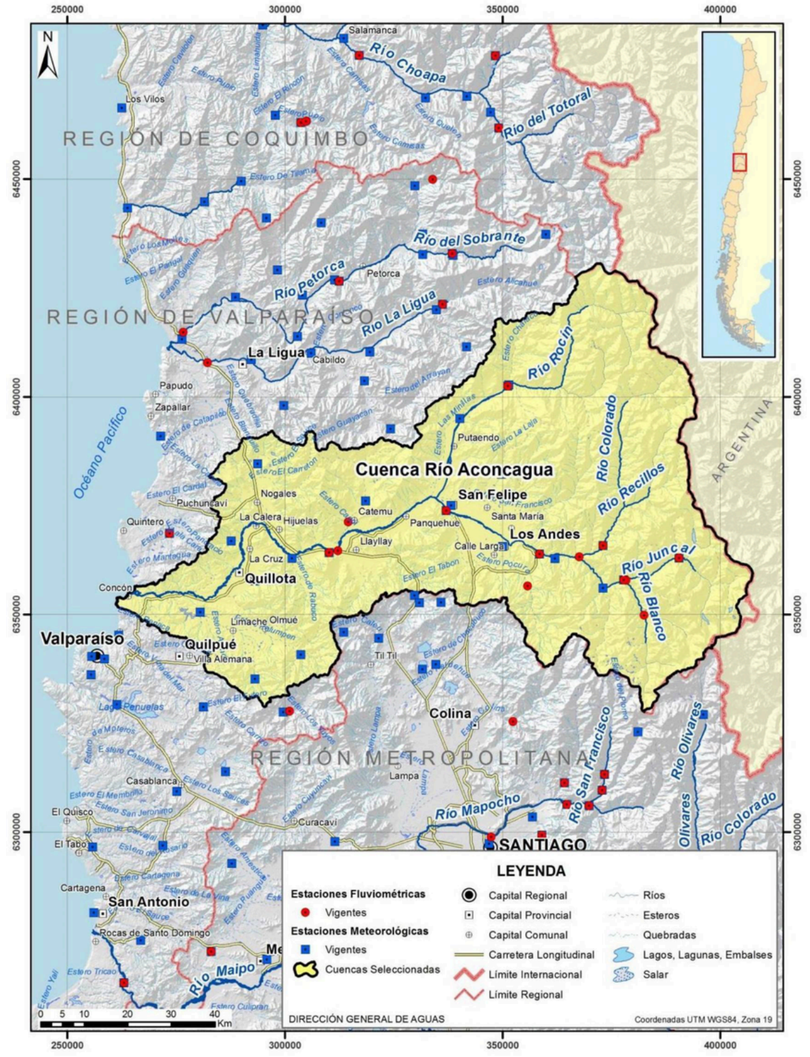
Población y construcción de variable respuesta

Concepto	Descripción
Población de estudio	Observaciones diarias de las 30 cuencas chilenas durante el período 2000–2016.
Unidad de observación	Par (cuenca, fecha) que identifica cada registro. Se define Q_t como el caudal observado durante el día t, con $t \in \{1, 2, \ldots, 6210\}$.
Variable respuesta	Caudal del día siguiente, definido como Q_{t+1}.

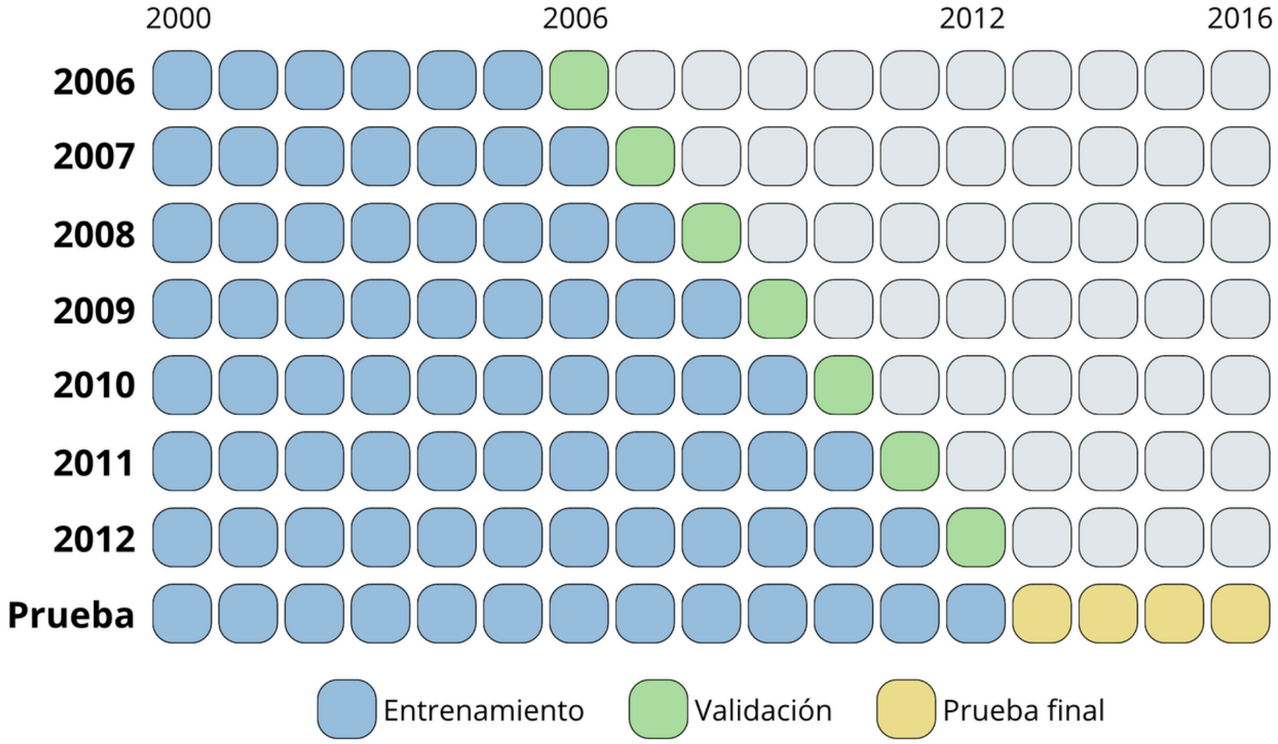
Cuadro 2: Población de estudio, unidad de observación y variable respuesta

Archivo	Descripción	Observaciones
`caudal_m3s.csv`	Caudal diario de las 30 cuencas (m^3/s)	6.210
`precipitacion_mm.csv`	Precipitación diaria (mm/día)	6.210
`temperatura_media_c.csv`	Temperatura media diaria (°C)	6.210
`atributos.csv`	Atributos físicos, climáticos e hidrológicos	30

Cuadro 3: Archivos originales utilizados en el análisis



Diseño de validación, información disponible y referencia



$$\hat{Q}^{\text{persistencia}}_{i,t+1} = Q_{i,t}$$

Referencia estacional

Predicción con la mediana histórica del caudal de cada cuenca para el mismo mes.

Solo se consideró **información disponible al final del día t**, excluyendo índices hidrológicos y resúmenes climáticos calculados sobre toda la serie.

Métodos

Regresión penalizada (Ridge y Lasso)

Modelo aditivo generalizado (GAM)

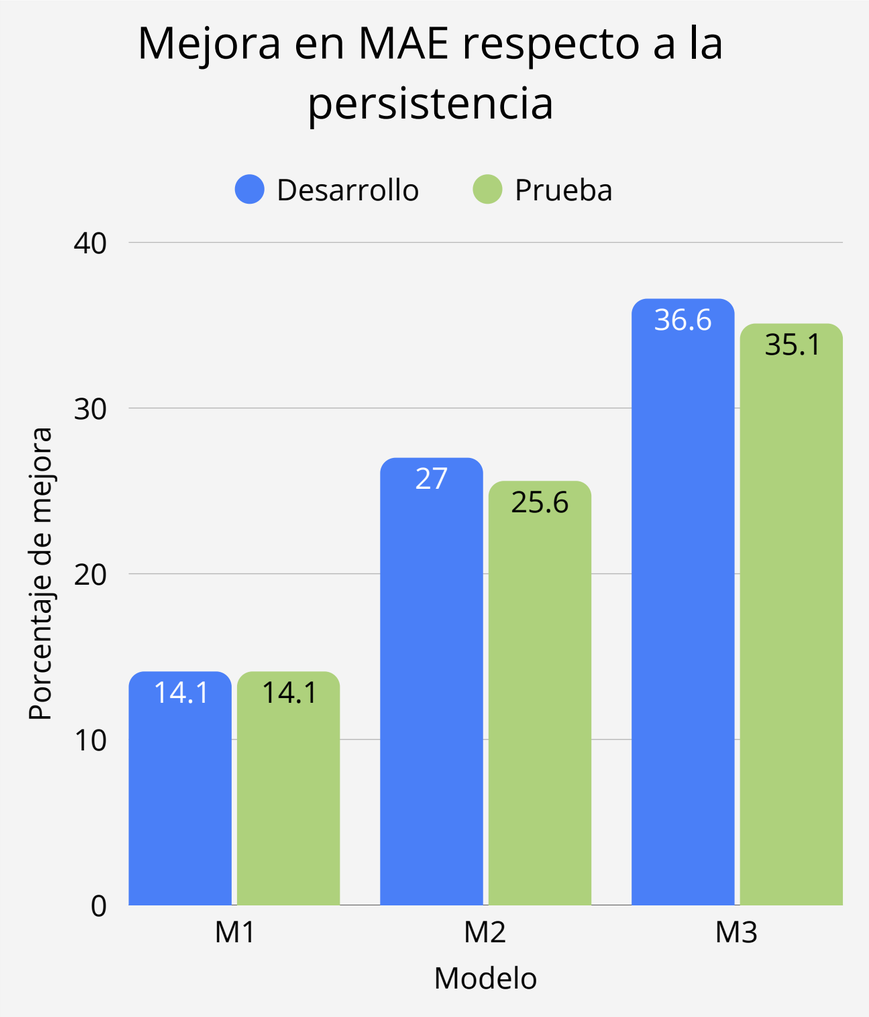
Random Forest

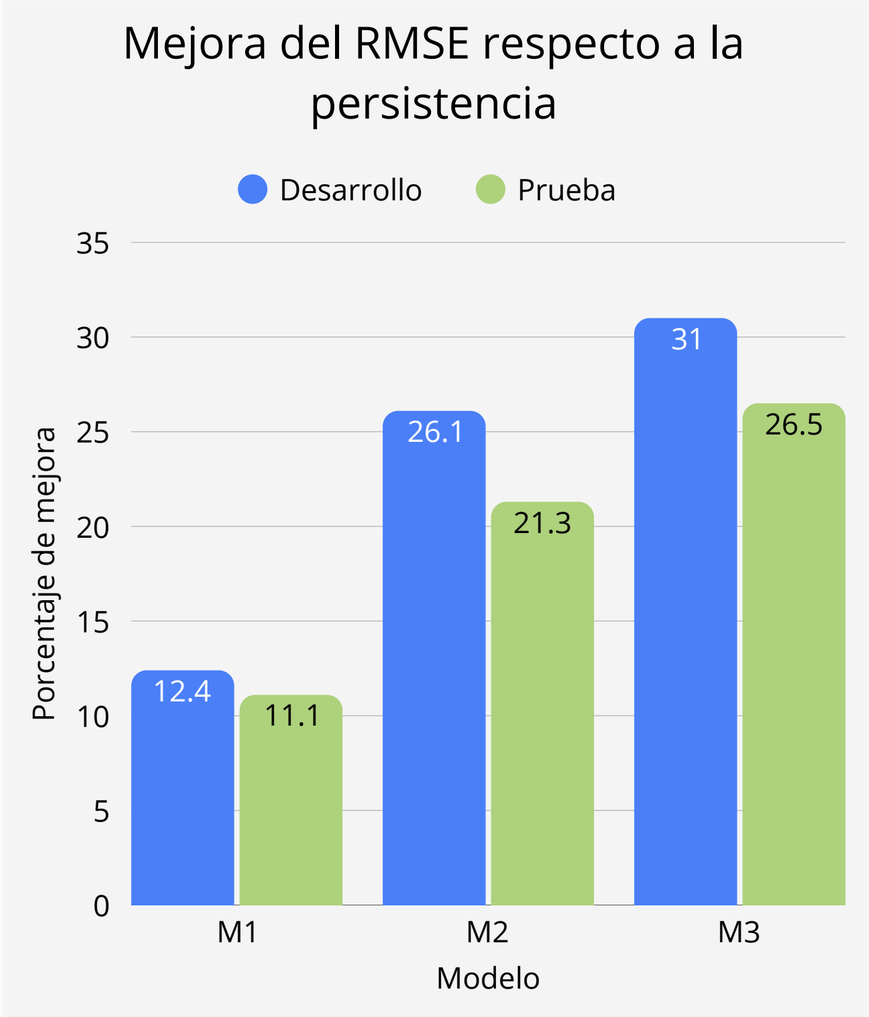
- **A**: Incorpora efecto de cada cuenca
- **B**: Función suave precipitación actual por cuenca
- **C**: función suave específica por cuenca para el log del caudal actual

Procedimiento	**Hiperparámetros evaluados**	**Configuraciones**
M1: Ridge/Lasso	$\alpha \in \{0, 1\}$ $\lambda \in \{0;\ 0{,}0001;\ 0{,}0003;\ 0{,}001;\ 0{,}003;\ 0{,}01;\ 0{,}03;\ 0{,}1\}$	16
M2: GAM	Estructuras A, B y C con $k = 5, 10$; adicionalmente C con $k = 15$	7
M3: Random Forest	mtry $= 2, 3, 5$ con nodesize $= 5, 25$; adicionalmente mtry $=$ 8 y nodesize $= 5$	7
Total		**30**

Cuadro 4: Hiperparámetros y presupuesto de búsqueda por procedimiento

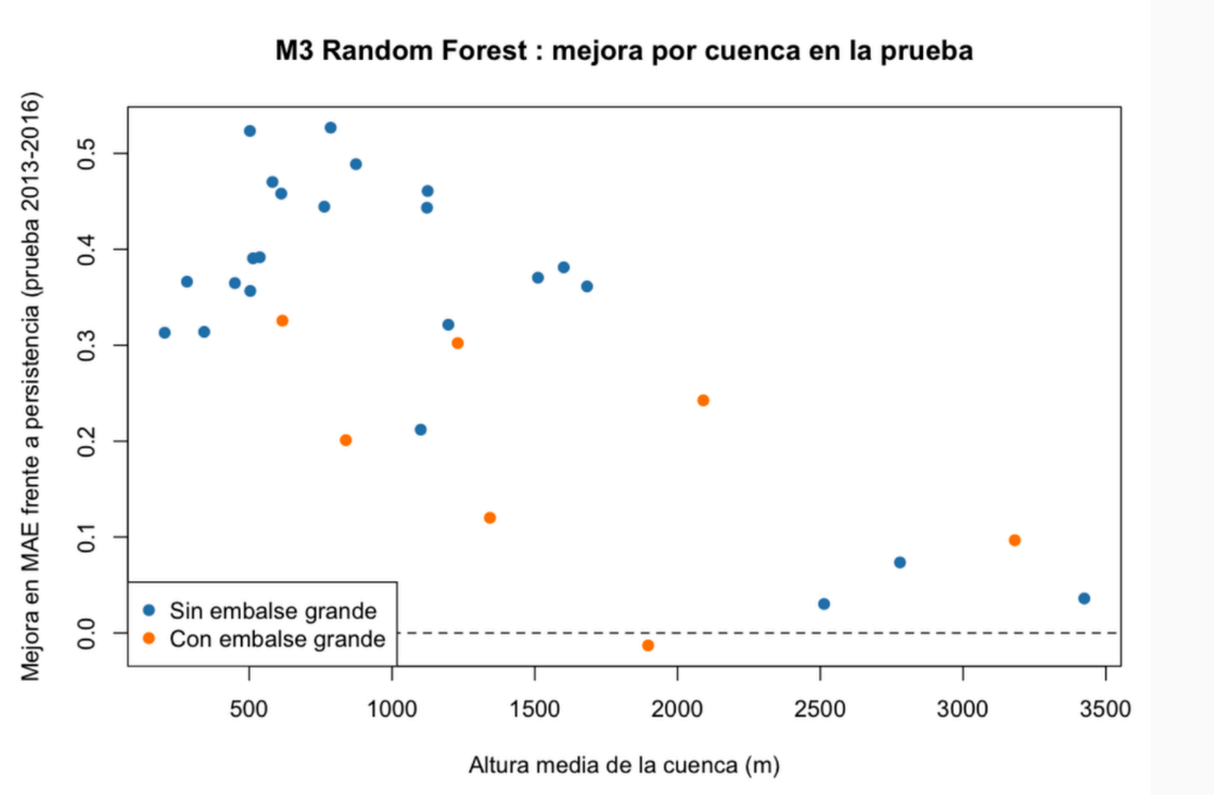
Resultados

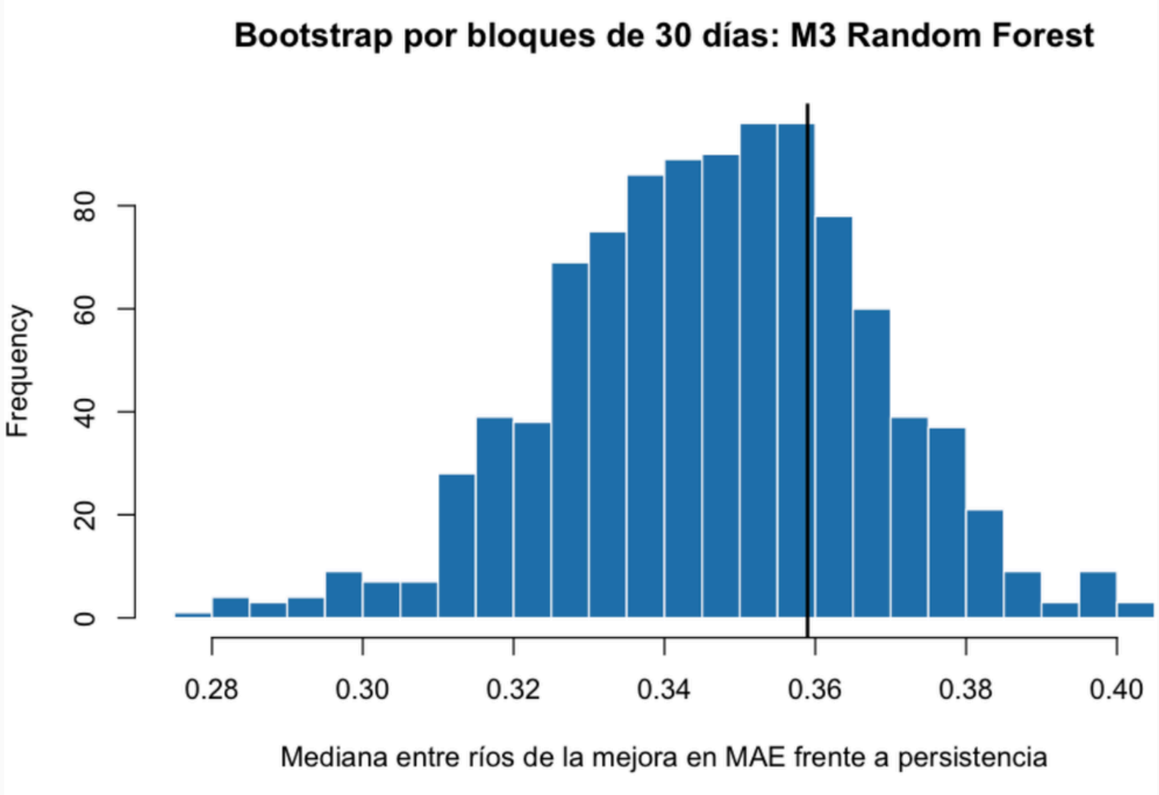




29 de 30
cuencas con mejora

Diagnóstico e incertidumbre





Sensibilidad

Variante	Mejora MAE	Mejora RMSE	Peor año (MAE)	Dif. MAE
M3 ganador (cambio log, código de cuenca)	0.366	0.310	0.297	—
S1: respuesta en m^3/s	0.243	0.225	0.144	-0.123
S3: atributos físicos en vez de cuenca	0.354	0.295	0.300	-0.012

Cuadro 6: Sensibilidades de representación de los datos para M3 (desarrollo, promedio de las 7 ventanas 2006–2012). Mejora relativa frente a persistencia

Familia	7 ventanas		3 ventanas	
	Configuración	Mejora MAE	Configuración	Mejora MAE
M1 ridge/lasso	ridge, $\lambda = 0{,}001$	0.136	ridge, $\lambda = 0{,}03$	0.133
M2 GAM	C_k10	0.270	C_k10	0.226
M3 random forest	**mtry 8, nodo 5**	**0.366**	**mtry 8, nodo 5**	**0.340**

En negrita, la familia elegida con cada esquema: M3 en ambos casos.

Cuadro 7: Sensibilidad de validación: configuración elegida con 7 ventanas (2006–2012) o 3 ventanas (2010–2012). Mejora en MAE frente a persistencia

Límites y recomendaciones

La Respuesta

Random Forest reduce el error de persistencia un **35.1%** (MAE) en la prueba final (2013-2016), incluso en años de megasequía.

La Cordillera

El modelo no es confiable para ríos sobre los 1.500 metros de altura, depende de la lluvia no del deshielo. Requiere entrenamiento constante

¿Dónde usarlo?

Altamente recomendable para la crecida de ríos en valles y zonas lluviosas. Para cuencas cordilleranas se debe completar la base con datos sobre deshielos.

Muchas Gracias

Referencias

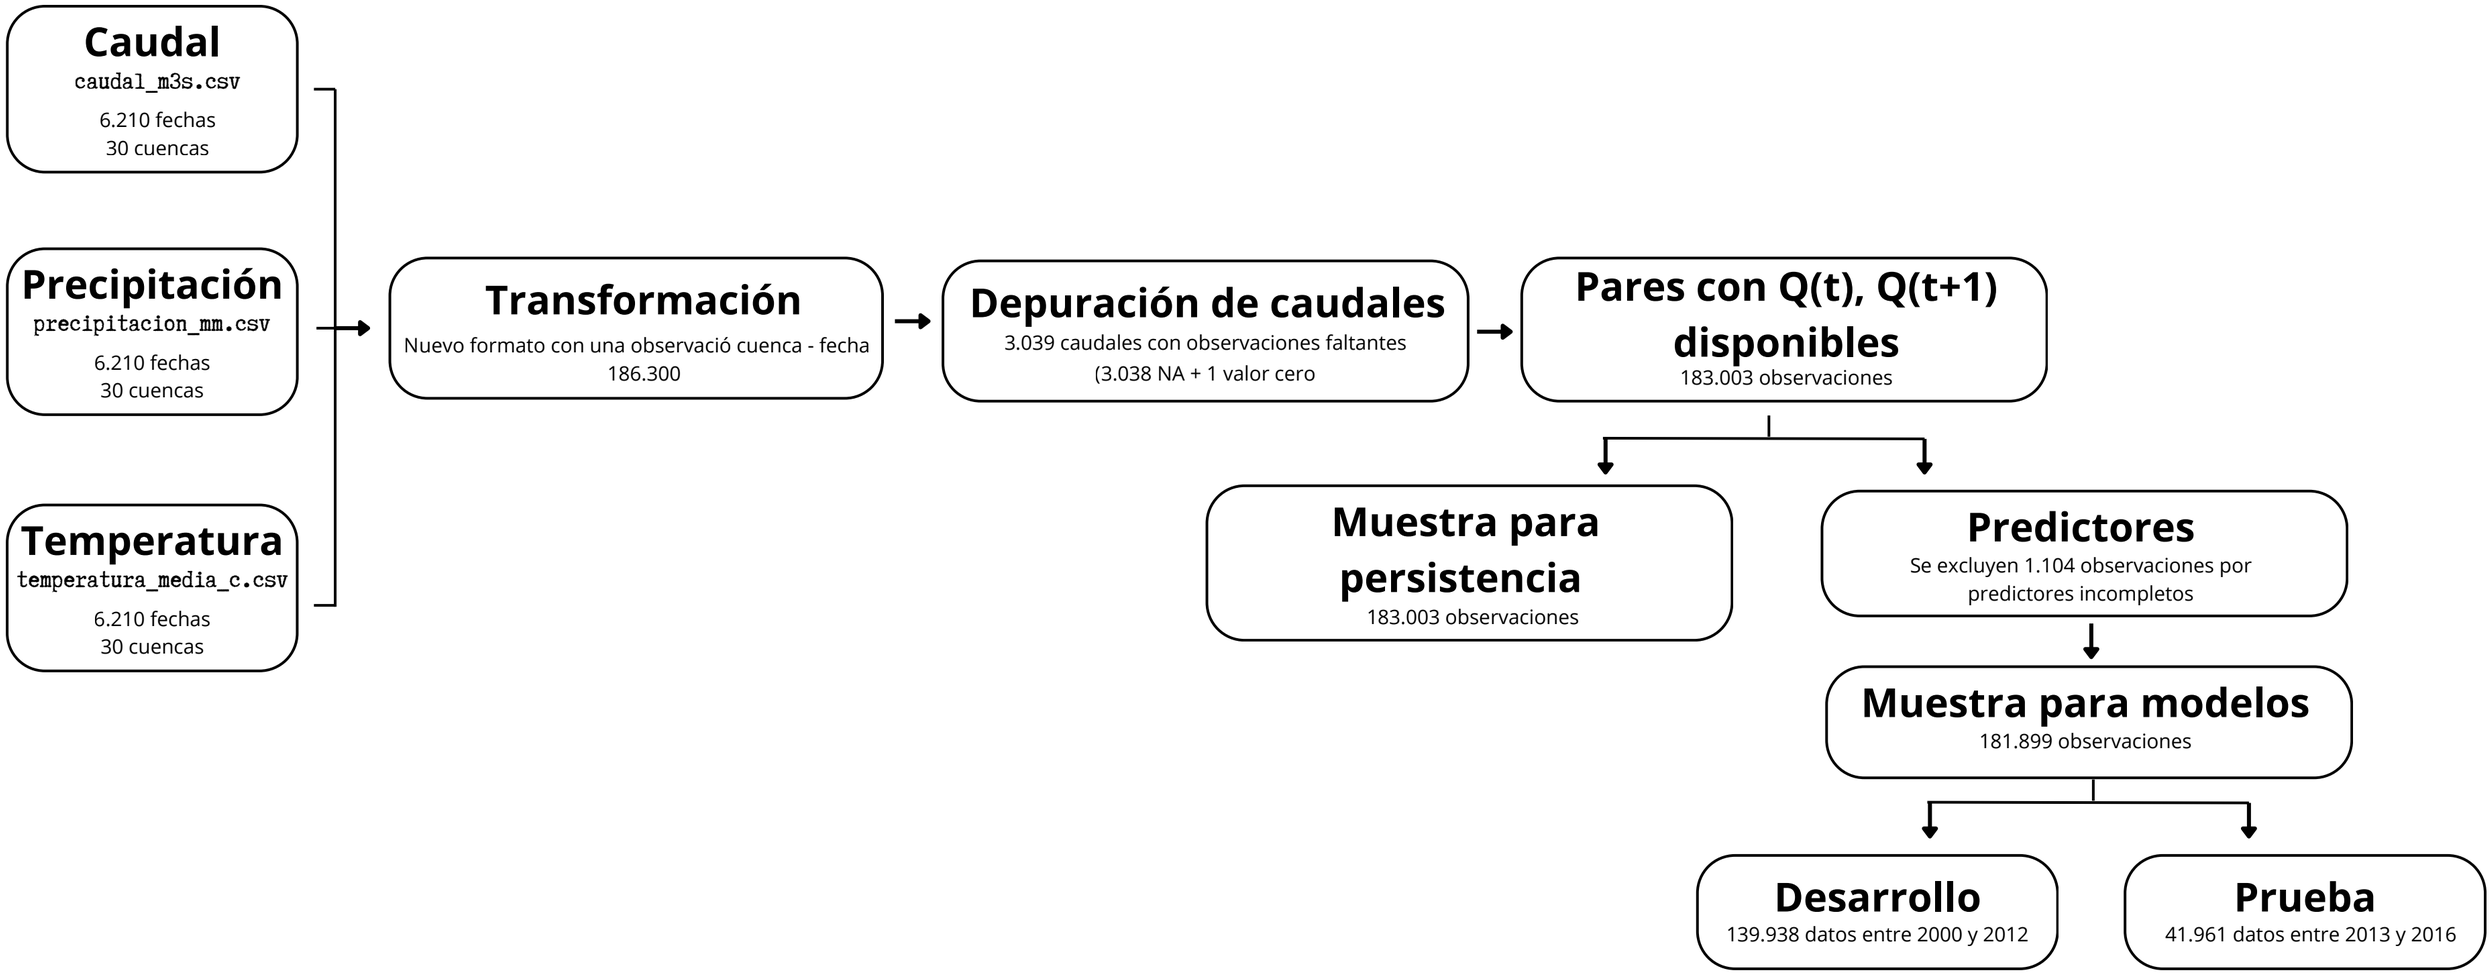
Alvarez-Garreton, C., Mendoza, P. A., Boisier, J. P., Addor, N., Galleguillos, M., Zambrano-Bigiarini, M., Lara, A., Puelma, C., Cortes, G., Garreaud, R., McPhee, J., and Ayala, A.: The CAMELS-CL dataset: catchment attributes and meteorology for large sample studies – Chile dataset, Hydrology and Earth System Sciences.

Washington State Department of Ecology. (s. f.). What is a watershed and why does it mat- ter?, https://ecology.wa.gov/ecologys-work-near-you/river-basins-groundwater/what-is-a-watershed- and-why-does-it-matter

Garreaud, R. D., Boisier, J. P., Rondanelli, R., Montecinos, A., Sepúlveda, H. H., & Veloso-Aguila, D. (2020). The Central Chile Mega Drought (2010–2018): A climate dynamics perspective. International Journal of Climatology, 40(1), 421–439. https://doi.org/10.1002/joc.6219

Dirección General de Aguas. (2004). Diagnóstico y clasificación de los cursos y cuerpos de agua según objetivos de calidad: Cuenca del río Toltén

Esquema de construcción



Etapa	**Observaciones**
Registros iniciales (30 cuencas × 6.210 días)	186.300
Cantidad de caudales NA	3.038
Cantidad de caudales con $Q_t = 0$	1
Total de caudales faltantes tras limpieza	3.039
Observaciones con Q_t y Q_{t+1} disponibles	183.003
Cantidad de obs. excluidas por predictores incompletos	1.104
Observaciones con respuesta y predictores completos	181.899
Observaciones entrenamiento	139.938
Observaciones prueba	41.961

Cuadro 8: Construcción de la muestra

Variable	Decisión	Motivo
Q_t	Incluir	Es caudal actual
Q_{t-1}	Incluir	Es caudal fecha anterior
$\log(Q_t)$	Incluir	Reduce asimetría
cambio_hoy	Incluir	$\log(Q_t) - \log(Q_{t-1})$
P	Incluir	Precipitación actual
P_{t-1}	Incluir	Precipitación fecha anterior
lluvia_3d	Incluir	Precipit. acumulada últimas 3 fechas
lluvia_7d	Incluir	Precipit. acumulada últimas 7 fechas
lluvia_30d	Incluir	Precipit. acumulada últimas 30 fechas
Temp	Incluir	Temperatura promedio actual
temp_7d	Incluir	Temperatura promedio últimas 7 fechas
mes	Incluir	Estacionalidad
cuenca	Incluir	Id de cuenca.
Q_{t+1}	Excluir	Variable respuesta
cambio_manana	Excluir	Respuesta transformada; objetivo del ajuste

Categoría	Decisión	Motivo
Topografía	Admisible	Estable; solo en sensibilidad y diagnóstico
Geología	Admisible	Cambio lento; no utilizada
Cobertura terrestre	Admisible	Puede cambiar; solo en sensibilidad
Índices climáticos	Excluir	Fuga de información
Índices hidrológicos	Excluir	Fuga de información
Intervención humana	Admisible	Embalses; solo en sensibilidad y diagnóstico

Cuadro 9: Auditoría de variables predictoras y atributos de las cuencas